


**ANALISIS SPATIAL TIME-SERIES DATA UNTUK IDENTIFIKASI
POLA KECEPATAN DAN ARUS LALU LINTAS DI JALAN
MALIOBORO BERBASIS ACTIVE MOBILE POSITIONING DATA**

SKRIPSI



Disusun oleh:

Rizky Intan Nurlita
20/456379/TK/50509

**PROGRAM STUDI TEKNOLOGI INFORMASI
DEPARTEMEN TEKNIK ELEKTRO DAN TEKNOLOGI INFORMASI
FAKULTAS TEKNIK UNIVERSITAS GADJAH MADA
YOGYAKARTA
2024**

HALAMAN PENGESAHAN

**ANALISIS *SPATIAL TIME-SERIES DATA* UNTUK IDENTIFIKASI POLA
KECEPATAN DAN ARUS LALU LINTAS DI JALAN MALIOBORO BERBASIS
*ACTIVE MOBILE POSITIONING DATA***

SKRIPSI

Diajukan sebagai Salah Satu Syarat untuk Memperoleh

Gelar Sarjana Teknik

pada Departemen Teknik Elektro dan Teknologi Informasi Fakultas Teknik

Universitas Gadjah Mada



Disusun oleh :

Rizky Intan Nurlita
20/456379/TK/50509

Telah disetujui dan disahkan

pada tanggal, 01 Juli 2024

Dosen Pembimbing I

Ir. Azkario Rizky Pratama, S.T., M.Eng., Ph.D.
NIP. 111199102201607102

Dosen Pembimbing II

Widyawan, S.T., M.Sc., Ph.D.
NIP. 197312042002121001



SKRIPSI

**ANALISIS SPATIAL TIME-SERIES DATA UNTUK IDENTIFIKASI POLA
KECEPATAN DAN ARUS LALU LINTAS DI JALAN MALIOBORO BERBASIS
ACTIVE MOBILE POSITIONING DATA**

Dipersiapkan dan disusun oleh

Rizky Intan Nurlita
20/456379/TK/50509

Telah dipertahankan di depan dewan penguji
pada tanggal : **01 Juli 2024**

Susunan Dewan Penguji

Pembimbing Utama

Ir. Azkario Rizky Pratama, S.T., M.Eng., Ph.D.

Pembimbing Pendamping

Widyawan, S.T., M.Sc., Ph.D.

Anggota Dewan Penguji Lain

Eny Sukani Rahayu, S.T., M. Eng.

Dr. Ir. Guntur Dharma Putra, S.T., M.Sc.

Skripsi ini telah diterima sebagai salah satu persyaratan
untuk memperoleh gelar Sarjana Teknik

Tanggal: 15 Juli 2024

Pengelola Program Studi: Sarjana Teknologi Informasi

Ir. Agus Bejo, S.T., M.Eng., D.Eng., IPM.

NIP 198001012015041002

Mengetahui,

Ketua Departemen Teknik Elektro dan Teknologi Informasi



Prof. Ir. Hanung Adi Nugroho, S.T., M.Eng., Ph.D., IPM., SMIEEE.

NIP 197802242002121001



PERNYATAAN BEBAS PLAGIASI

Saya yang bertanda tangan di bawah ini :

Nama : Rizky Intan Nurlita
NIM : 20/456379/TK/50509
Tahun terdaftar : 2020
Program Studi : Teknologi Informasi
Fakultas : Teknik

Menyatakan bahwa dalam dokumen ilmiah Skripsi ini tidak terdapat bagian dari karya ilmiah lain yang telah diajukan untuk memperoleh gelar akademik di suatu lembaga Pendidikan Tinggi, dan juga tidak terdapat karya atau pendapat yang pernah ditulis atau diterbitkan oleh orang/lembaga lain, kecuali yang secara tertulis disitasi dalam dokumen ini dan disebutkan sumbernya secara lengkap dalam daftar pustaka.

Dengan demikian saya menyatakan bahwa dokumen ilmiah ini bebas dari unsur-unsur plagiasi dan apabila dokumen ilmiah Skripsi ini di kemudian hari terbukti merupakan plagiasi dari hasil karya penulis lain dan/atau dengan sengaja mengajukan karya atau pendapat yang merupakan hasil karya penulis lain, maka penulis bersedia menerima sanksi akademik dan/atau sanksi hukum yang berlaku.

Yogyakarta, 17-07-2024



Rizky Intan Nurlita
20/456379/TK/50509

HALAMAN PERSEMBAHAN

Tugas akhir ini aku persembahkan kepada kedua orang tua, Mama dan Papa, yang selalu memberikan dukungan penuh dalam setiap langkah hidupku. Kupersembahkan pula kepada keluarga, teman-teman tercinta, serta untuk bangsa, negara, dan agamaku. Terakhir, kepada diriku sendiri yang telah berusaha dan bertahan sampai detik ini.

Terima kasih sudah berjuang, Intan.

KATA PENGANTAR

Puji syukur ke hadirat Allah SWT atas limpahan rahmat, karunia, serta petunjuk-Nya sehingga tugas akhir berupa penyusunan skripsi ini telah terselesaikan dengan baik, meski melalui banyak halangan dan tantangan dalam prosesnya. Dalam hal penyusunan tugas akhir ini penulis telah banyak mendapatkan arahan, bantuan, serta dukungan dari berbagai pihak. Oleh karena itu pada kesempatan ini penulis mengucapkan terima kasih kepada:

1. Bapak Ir. Hanung Adi Nugroho, S.T., M.E., Ph.D., IPM. selaku Ketua Departemen Teknik Elektro dan Teknologi Informasi, Fakultas Teknik, Universitas Gadjah Mada.
2. Bapak Ir. Lesnanto Multa Putranto, S.T., M.Eng, Ph.D., IPM. selaku Sekretaris Departemen Teknik Elektro dan Teknologi Informasi, Fakultas Teknik, Universitas Gadjah Mada.
3. Bapak Azkario Rizky Pratama, S.T., M.Eng., Ph.D., selaku dosen pembimbing pertama dan Bapak Widyawan, S.T., M.Sc., Ph.D. selaku dosen pembimbing kedua yang telah memberikan arahan, bimbingan, serta motivasi selama penyusunan tugas akhir ini.
4. Kedua orang tua penulis, Mama dan Papa yang selalu memberikan dukungan penuh dalam setiap proses kehidupan yang penulis jalani, serta senantiasa memberikan doa dan semangat tiada henti kepada penulis.
5. Kedua adik lelaki serta anjing penulis, Micky, Mikha dan Oli yang terkadang membuat penulis kesal selama pengerjaan tugas akhir di rumah, tetapi juga menjadi sumber kebahagiaan dan keceriaan.
6. Teman seperjuangan perkuliahan, Sayyidan, yang selalu bersedia hadir sebagai *support system* terbaik, serta tempat berkeluh kesah selama pengerjaan tugas akhir.
7. Mas Akhrham, Alfath, Farhan, Asa, Dinda, dan Rei, selaku teman bimbingan yang saling memberikan dukungan serta inspirasi selama pengerjaan tugas akhir.
8. Teman-teman terdekat penulis yang telah menjadi teman terbaik selama ini. Terima kasih untuk 3 Biduan, Ayank, Squad, Alma, Pri Order, Capstone Ayam, KKN Pesarangan, Debats, Padz'75, dan teman-teman lainnya yang tidak dapat disebutkan satu persatu.
9. Teman-teman TETI'20 yang saat ini sedang sama-sama berjuang untuk menyelesaikan tugas akhir. Semoga kita semua dapat sukses dan meraih impian dan cita-cita yang kita harapkan selama ini.
10. Serta pihak-pihak lain yang tidak dapat disebutkan satu persatu yang telah memberikan dukungan, bantuan, serta motivasi selama proses penyusunan tugas akhir ini.

Penulis menyadari bahwa tugas akhir ini masih jauh dari kata sempurna. Oleh sebab itu, penulis sangat mengharapkan kritik dan saran yang membangun untuk perbaikan di penelitian selanjutnya. Akhir kata, semoga tugas akhir ini dapat memberikan manfaat bagi siapa saja yang membacanya.

Yogyakarta, 19 Juni 2024

Rizky Intan Nurlita

DAFTAR ISI

HALAMAN PENGESAHAN	ii
PERNYATAAN BEBAS PLAGIASI	iii
HALAMAN PERSEMBAHAN	iv
KATA PENGANTAR	vi
DAFTAR ISI	vii
DAFTAR TABEL	ix
DAFTAR GAMBAR	x
DAFTAR SINGKATAN.....	xi
INTISARI.....	xii
ABSTRACT	xiii
BAB I Pendahuluan	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan Penelitian	3
1.4 Batasan Penelitian	3
1.5 Manfaat Penelitian	4
1.6 Sistematika Penulisan.....	4
BAB II Tinjauan Pustaka dan Dasar Teori	6
2.1 Tinjauan Pustaka	6
2.2 Dasar Teori	18
2.2.1 Kecepatan Lalu Lintas	18
2.2.2 Arus Lalu Lintas	19
2.2.3 <i>Mobile Positioning Data</i> (MPD)	19
2.2.4 <i>Map Matching</i>	20
2.2.5 <i>K-Dimensional Tree</i> (KDTree)	21
2.2.6 <i>Hidden Markov Model</i> (HMM)	22
2.2.7 PyTrack	23
2.2.8 MovingPandas.....	24
2.2.9 Koefisien Korelasi Pearson	24
2.2.10 <i>Dynamic Time Warping</i> (DTW)	25
2.2.11 <i>Haversine Formula</i>	26
BAB III Metode Penelitian.....	27
3.1 Alat dan Bahan Tugas Akhir	27
3.1.1 Alat Tugas Akhir	27
3.1.2 Bahan Tugas Akhir.....	28
3.2 Metode yang Digunakan.....	31

3.3	Alur Tugas Akhir	32
3.3.1	Mengumpulkan Data.....	32
3.3.2	<i>Preprocessing Data</i>	33
3.3.3	Mengeliminasi <i>Stay Locations</i>	34
3.3.4	Mengeliminasi Titik Jarak >20 meter dari Ruas Jalan	34
3.3.5	<i>Map Matching</i> dengan Algoritma KDTree	35
3.3.6	<i>Immobility Filter</i>	36
3.3.7	Menyesuaikan Titik dengan Arah Jalur Jalan.....	36
3.3.8	<i>Split Trajectory</i> berdasarkan Waktu Observasi	39
3.3.9	<i>Path Reconstruction</i>	40
3.3.10	Interpolasi Waktu	41
3.3.11	Perhitungan Kecepatan dan Arus Lalu Lintas	42
3.3.12	Analisis Pola Lalu Lintas	43
3.3.13	Membandingkan Hasil Analisis dengan Data <i>Ground Truth</i>	44
3.4	Keterbatasan Penelitian	45
BAB IV	Hasil dan Pembahasan.....	46
4.1	Rekonstruksi Rute Perjalanan Kendaraan	46
4.1.1	Data MPD Aktif Setelah Tahap <i>Preprocessing Data</i>	46
4.1.2	Rekonstruksi Rute Perjalanan menggunakan Metode <i>Path Recon-</i> <i>struction</i> dan Interpolasi Waktu	49
4.2	Analisis Pola Kecepatan dan Arus Lalu Lintas	54
4.2.1	Perhitungan Kecepatan dan Arus Lintas	54
4.2.2	Analisis Pola Kecepatan Lalu Lintas	56
4.2.3	Analisis Pola Arus Lalu Lintas	60
4.3	Perbandingan Hasil Analisis Pola Lalu Lintas dengan Data <i>Ground Truth</i> .	61
4.3.1	Perbandingan Kecepatan Lalu Lintas dengan Data Google Maps ..	61
4.3.2	Perbandingan Arus Lalu Lintas dengan Data Dinas Perhubungan DIY	63
BAB V	Kesimpulan dan Saran.....	65
5.1	Kesimpulan.....	65
5.2	Saran.....	66
DAFTAR PUSTAKA		67

DAFTAR TABEL

Tabel 2.1	Ringkasan perbandingan penelitian terdahulu	14
Tabel 2.2	Kolom fitur MPD aktif	20
Tabel 2.3	Rentang interpretasi hubungan koefisien Korelasi Pearson	25
Tabel 3.1	Fitur dataset MPD aktif	28
Tabel 3.2	Fitur dataset <i>shapefile</i> ruas jalan	29
Tabel 3.3	Fitur dataset riwayat kecepatan lalu lintas Google Maps	30
Tabel 3.4	Fitur dataset survei arus lalu lintas Dinas Perhubungan DIY	31
Tabel 4.1	Hasil implementasi <i>preprocessing data</i>	48
Tabel 4.2	Sampel hasil implementasi <i>split trajectory</i> dan <i>path reconstruction</i> ..	53
Tabel 4.3	Perubahan jumlah titik GPS dan <i>trajectory</i> pada setiap tahap	55
Tabel 4.4	Fitur DataFrame hasil perhitungan kecepatan lalu lintas	56
Tabel 4.5	Statistik deskriptif kecepatan lalu lintas	57
Tabel 4.6	Hasil perhitungan jarak DTW untuk perbandingan kecepatan per hari	62
Tabel 4.7	Hasil perbandingan kecepatan dengan data Google Maps	63
Tabel 4.8	Hasil perbandingan arus dengan data Dinas Perhubungan DIY	64

DAFTAR GAMBAR

Gambar 2.1	Contoh ilustrasi proses <i>map matching</i>	21
Gambar 2.2	Dua <i>time-series</i> data yang dibandingkan	25
Gambar 2.3	Ilustrasi jarak <i>great circle</i> antara dua titik (A dan B) pada bidang bola	26
Gambar 3.1	Sampel data MPD aktif	28
Gambar 3.2	Sampel <i>shapefile</i> data ruas jalan	29
Gambar 3.3	Sampel data riwayat kecepatan lalu lintas Google Maps	30
Gambar 3.4	Sampel data survei arus lalu lintas Dinas Perhubungan DIY	30
Gambar 3.5	Alur penelitian	33
Gambar 3.6	<i>Flowchart</i> metode <i>preprocessing data</i>	33
Gambar 3.7	<i>Flowchart</i> metode eliminasi <i>stay locations</i>	34
Gambar 3.8	<i>Flowchart</i> metode eliminasi titik jarak >20 meter dari ruas jalan .	35
Gambar 3.9	<i>Flowchart</i> metode <i>map matching</i> dengan algoritma KDTree.....	35
Gambar 3.10	<i>Flowchart</i> metode <i>immobility filter</i>	37
Gambar 3.11	<i>Flowchart</i> metode menyesuaikan titik dengan arah jalur jalan	38
Gambar 3.12	<i>Flowchart</i> metode <i>split trajectory</i>	40
Gambar 3.13	<i>Flowchart</i> metode <i>path reconstruction</i>	40
Gambar 3.14	<i>Flowchart</i> metode interpolasi waktu	42
Gambar 3.15	<i>Flowchart</i> metode perhitungan kecepatan dan arus lalu lintas	43
Gambar 4.1	Distribusi maid unik setiap harinya	47
Gambar 4.2	Sampel data GPS sebelum dilakukan <i>split trajectory</i>	49
Gambar 4.3	Sampel data GPS setelah dilakukan <i>split trajectory</i>	50
Gambar 4.4	Proses rekonstruksi rute perjalanan dengan <i>library</i> PyTrack	51
Gambar 4.5	Sampel DataFrame titik GPS awal	51
Gambar 4.6	Sampel DataFrame hasil rekonstruksi rute perjalanan	52
Gambar 4.7	Sampel DataFrame setelah rekonstruksi rute perjalanan dan interpolasi waktu	52
Gambar 4.8	Poligon <i>buffer</i> dan kumpulan titik GPS yang berada di Jalan Malioboro	54
Gambar 4.9	DataFrame hasil perhitungan kecepatan lalu lintas.....	56
Gambar 4.10	Histogram distribusi data kecepatan bulan Januari-Februari 2022	58
Gambar 4.11	Histogram distribusi data kecepatan berdasarkan kategori hari kerja dan akhir pekan	58
Gambar 4.12	<i>Heatmap</i> rata-rata distribusi kecepatan berdasarkan hari dan jam.	59
Gambar 4.13	<i>Line chart</i> perubahan arus berdasarkan kategori hari kerja dan akhir pekan	60
Gambar 4.14	<i>Line chart</i> perbandingan kecepatan dengan Google Maps	62
Gambar 4.15	<i>Scatter plot</i> perbandingan kecepatan dengan data Google Maps ..	63
Gambar 4.16	<i>Scatter plot</i> perbandingan arus dengan data Dinas Perhubungan DIY	64

DAFTAR SINGKATAN

MPD	=	Mobile Positioning Data
CFN	=	Car Free Night
GT	=	Ground Truth
DIY	=	Daerah Istimewa Yogyakarta
HPC	=	High Performance Computer
VPN	=	Virtual Private Network
CSV	=	Comma-Separated Values
OSM	=	Open Street Map
KDTree	=	K-Dimensional Tree
HMM	=	Hidden Markov Model
DTW	=	Dynamic Time Warping
API	=	Application Programming Interface
UGM	=	Universitas Gadjah Mada
SMP	=	Satuan Mobil Penumpang
GPS	=	Global Positioning System
SVR	=	Support Vector Regression
MAE	=	Mean Absolute Error
MSE	=	Mean Squared Error
RMSE	=	Root Mean Squared Error
CDR	=	Call Detail Record
DDR	=	Data Detail Record
GRU	=	Gated Recursive Unit
ARIMA	=	AutoRegressive Integrated Moving Average
LSTM	=	Long Short Term Memory
MAPE	=	Mean Absolute Percentage Error
EVS	=	Explained Variance Score

INTISARI

Kemacetan merupakan salah satu masalah kompleks yang dihadapi oleh kota-kota besar di Indonesia. Dalam mengatasi masalah ini, pemerintah perlu membuat kebijakan berdasarkan pada data terkait kecepatan dan arus lalu lintas. Namun, data lalu lintas yang diperoleh dari survei konvensional seringkali tidak efisien dalam hal waktu, biaya, dan tenaga. Penelitian membuktikan bahwa data *Geospatial Positioning System* (GPS) dapat menjadi alternatif yang efektif dan efisien dalam mengidentifikasi pola lalu lintas. Salah satu data GPS yang dapat digunakan adalah *active Mobile Positioning Data* (MPD) atau MPD aktif yang mencatat posisi telepon pengguna dengan teknologi GPS. Akan tetapi, penelitian terkait topik ini masih jarang dilakukan di Indonesia. Padahal, MPD aktif dapat memiliki potensi kelebihan dalam efisiensi dan efektivitas dalam menganalisis pola lalu lintas dibandingkan survei konvensional.

Oleh karena itu, penelitian ini bertujuan untuk mengidentifikasi pola kecepatan dan arus lalu lintas menggunakan MPD aktif di Jalan Malioboro, Yogyakarta. Dalam tujuan tersebut terdapat tiga objektif penelitian, yaitu merekonstruksi rute perjalanan pengguna, mengidentifikasi pola kecepatan dan arus lalu lintas, serta mengevaluasi hasil identifikasi tersebut dengan data *ground truth*. Metode yang digunakan menggunakan analisis deskriptif untuk memahami karakteristik kecepatan dan arus lalu lintas, serta analisis korelasi untuk mengukur akurasi data MPD aktif terhadap data *ground truth*.

Hasil penelitian menunjukkan bahwa pola kecepatan dan arus lalu lintas di Jalan Malioboro berbeda antara hari kerja dan akhir pekan. Pada hari kerja, kecepatan rata-rata lebih tinggi dengan puncak kecepatan di pagi hari dan penurunan signifikan di sore hari. Sebaliknya, pada akhir pekan, kecepatan cenderung lebih rendah dan fluktuatif sepanjang hari. Arus lalu lintas juga lebih tinggi pada hari kerja dibandingkan akhir pekan, dengan puncak arus terjadi pada sore hari.

Evaluasi hasil analisis dengan data *ground truth* dari Google Maps dan Dinas Perhubungan Daerah Istimewa Yogyakarta (DIY) menunjukkan bahwa MPD aktif dapat memberikan gambaran yang cukup akurat tentang pola lalu lintas di Jalan Malioboro. Meskipun terdapat beberapa *outlier* dan variabilitas, hasil analisis menunjukkan kesesuaian yang cukup baik dengan data *ground truth*, terutama pada hari kerja. Penelitian ini menyarankan perlunya evaluasi lebih lanjut dan pengumpulan data tambahan untuk meningkatkan akurasi dan memahami faktor-faktor lain yang mempengaruhi pola kecepatan dan arus lalu lintas.

Kata kunci : *mobile positioning data*, data GPS, kecepatan lalu lintas, arus lalu lintas, *path reconstruction*.

ABSTRACT

Traffic congestion is a complex issue faced by major cities in Indonesia. To address this problem, government policies must be based on data related to traffic speed and flow. However, conventional traffic surveys are often inefficient in terms of time, cost, and labor. Research has shown that Geospatial Positioning System (GPS) data can be an effective and efficient alternative for identifying traffic patterns. One such GPS data source is active Mobile Positioning Data (MPD), which records the positions of users' phones using GPS technology. Despite its potential advantages, research on this topic is still scarce in Indonesia.

This study aims to identify traffic speed and flow patterns using active MPD on Jalan Malioboro, Yogyakarta. The research objectives include reconstructing users' travel routes, identifying traffic speed and flow patterns, and evaluating these patterns against ground truth data. The methodology involves descriptive analysis to understand the characteristics of traffic speed and flow, as well as correlation analysis to measure the accuracy of active MPD against ground truth data.

The results show that traffic speed and flow patterns on Jalan Malioboro differ between weekdays and weekends. On weekdays, average speed is higher with peak speeds in the morning and a significant decline in the evening. Conversely, on weekends, speeds tend to be lower and more fluctuating throughout the day. Traffic flow is also higher on weekdays compared to weekends, with peak flow occurring in the evening.

Evaluation against ground truth data from Google Maps and Dinas Perhubungan Daerah Istimewa Yogyakarta (DIY) indicates that active MPD provides a reasonably accurate depiction of traffic patterns on Jalan Malioboro. Although there are some outliers and variability, the analysis results align well with ground truth data, especially on weekdays. This study suggests the need for further evaluation and additional data collection to improve accuracy and understand other factors influencing traffic speed and flow patterns.

Keywords : *mobile positioning data, GPS, traffic speed, traffic density, path reconstruction.*

BAB I

PENDAHULUAN

1.1 Latar Belakang

Dalam era perkembangan perkotaan yang semakin padat, tantangan utama yang menjadi perhatian adalah masalah lalu lintas, salah satunya adalah kemacetan. Pertumbuhan populasi yang pesat, peningkatan jumlah kendaraan, dan infrastruktur jalan yang terbatas seringkali menyebabkan kemacetan di kota-kota besar di Indonesia. Kemacetan lalu lintas merupakan kondisi dimana jaringan transportasi mengalami penurunan kinerja yang ditandai dengan pergerakan yang lebih lambat, waktu perjalanan yang lebih lama, dan peningkatan antrian kendaraan [1]. Kemacetan ini menjadi masalah serius yang berpotensi menyebabkan berbagai macam kerugian, mulai dari segi ekonomi, lingkungan, hingga kesehatan akibat penurunan kualitas udara dari polusi emisi kendaraan [2]. Oleh karena itu, penting untuk mencari solusi yang tepat guna untuk mengatasi masalah kemacetan lalu lintas ini.

Sebagai upaya mengatasi permasalahan lalu lintas, pemerintah perlu membuat kebijakan yang berbasis pada data analisis kecepatan dan arus lalu lintas untuk memahami dinamika serta mencari solusi yang efektif dalam mengatasi masalah lalu lintas yang kompleks [3]. Saat ini, perhitungan kecepatan dan arus lalu lintas di Indonesia dihitung berdasarkan survei berkala berdasarkan pedoman yang dikeluarkan oleh Direktorat Jenderal Bina Marga, Kementerian Pekerjaan Umum dan Perumahan Rakyat. Metode pelaksanaan survei terdiri dari dua jenis, yaitu survei manual dan survei mekanis. Survei manual melibatkan tenaga surveyor untuk menghitung arus lalu lintas secara langsung, sedangkan survei mekanis menggunakan peralatan elektronis seperti tabung pneumatik, loop induksi, gelombang infra merah, dan kamera [4]. Akan tetapi, kedua metode ini memiliki beberapa kelemahan, survei manual membutuhkan biaya pengambilan data yang tinggi serta memakan banyak waktu dan tenaga. Sementara survei mekanis, memerlukan investasi awal yang cukup tinggi untuk membeli dan memelihara peralatan yang digunakan.

Dalam beberapa tahun terakhir, perkembangan teknologi informasi dan komunikasi telah membuka peluang baru untuk mengatasi masalah ini. Salah satu pendekatan yang menjanjikan adalah penggunaan data *Geospatial Positioning System* (GPS) untuk analisis lalu lintas. Penelitian mengenai kondisi lalu lintas menggunakan data GPS telah beberapa kali dilakukan. Salah satu penelitian yang relevan adalah studi oleh Forghani *et al.* [5], yang menunjukkan bahwa data GPS dapat diolah menjadi data lintasan yang lebih akurat untuk eksplorasi mobilitas. Penelitian lain adalah studi oleh Wang *et al.* [1] yang menggunakan data GPS dari perjalanan taksi untuk analisis kemacetan lalu lintas.

Penelitian ini menunjukkan bahwa data GPS dapat memberikan wawasan tentang pola pergerakan kendaraan dan kemacetan lalu lintas melalui visualisasi yang interaktif dan *real-time*. Selain itu, penelitian yang telah dilakukan di Indonesia salah satunya oleh Satrinia *et al.* [6] yang menggunakan data GPS dari perjalanan taksi untuk analisis kecepatan lalu lintas di Kota Bandung. Penelitian ini memprediksi kemacetan lalu lintas dengan metode *Support Vector Machine* (SVM) dan menunjukkan akurasi yang baik.

Salah satu sumber data GPS yang dapat digunakan adalah *active Mobile Positioning Data* (MPD) atau MPD aktif yang diperoleh dari perangkat *smartphone*. MPD merupakan data spasial temporal yang mencatat posisi telepon seluler [5]. MPD terbagi menjadi dua jenis, yaitu MPD pasif dan MPD aktif. MPD pasif diperoleh dari aktivitas penggunaan telepon seluler yang diambil dari *tower* operator seluler dengan tanpa intervensi pengguna, sehingga data ini memiliki kelebihan berupa cakupan yang lebih luas. Akan tetapi, data jenis ini memiliki ketidakpastian yang tinggi, dengan akurasi berkisar 100 meter di lokasi padat dan 30 km di lokasi terpencil [7]. Sementara itu, MPD aktif diperoleh dengan persetujuan pengguna operator seluler, dimana dibutuhkan mekanisme tertentu untuk mengumpulkan data lokasi pengguna, seperti penggunaan aplikasi tertentu yang melibatkan teknologi GPS [8].

Meskipun telah terdapat beberapa penelitian yang menggunakan data GPS untuk analisis kondisi lalu lintas, penelitian ini masih terbatas dan belum banyak dilakukan di Indonesia, khususnya dalam pemanfaatan MPD aktif. Padahal, MPD aktif memiliki kelebihan dari jumlah dan cakupan yang lebih besar dibandingkan dengan data GPS perjalanan seperti taksi atau bus. Sehubungan dengan hal tersebut, tujuan penelitian ini adalah menggunakan MPD aktif untuk menganalisis pola kecepatan dan arus lalu lintas di Jalan Malioboro, yang merupakan salah satu jalan utama di Kota Yogyakarta. Jalan Malioboro dikenal sebagai pusat kegiatan ekonomi, sosial, dan budaya di Yogyakarta, dengan karakteristik yang unik seperti lalu lintas yang padat dan beragamnya pengguna jalan. Dengan melakukan analisis pola lalu lintas di Jalan Malioboro, diharapkan penelitian ini dapat mengisi kesenjangan dalam penelitian yang jarang dilakukan mengenai pemanfaatan MPD aktif untuk menganalisis pola lalu lintas di Indonesia. Melalui pendekatan ini, diharapkan dapat diperoleh pemahaman yang lebih mendalam tentang bagaimana MPD aktif dapat digunakan untuk memahami dinamika lalu lintas dalam konteks perkotaan yang kompleks.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, penulis dapat merumuskan masalah sebagai berikut:

1. Belum terdapat penelitian yang melakukan rekonstruksi rute perjalanan pengguna di Jalan Malioboro menggunakan MPD aktif

2. Belum terdapat penelitian yang mengidentifikasi pola kecepatan dan arus lalu lintas di Jalan Malioboro menggunakan MPD aktif
3. Keakuratan hasil identifikasi pola kecepatan dan arus lalu lintas di Jalan Malioboro menggunakan MPD aktif belum diketahui

1.3 Tujuan Penelitian

Penelitian ini bertujuan untuk:

1. Merekonstruksi rute perjalanan pengguna menggunakan MPD aktif di Jalan Malioboro
2. Mengidentifikasi pola kecepatan dan arus lalu lintas di Jalan Malioboro dengan hasil rekonstruksi rute perjalanan pengguna
3. Mengevaluasi hasil identifikasi pola kecepatan dan arus lalu lintas di Jalan Malioboro menggunakan MPD aktif

1.4 Batasan Penelitian

Penelitian ini memiliki beberapa batasan, yaitu:

1. Objek penelitian: Analisis kecepatan dan arus lalu lintas di Jalan Malioboro, Provinsi Daerah Istimewa Yogyakarta menggunakan MPD Aktif
2. Metode penelitian: Penelitian ini menggunakan metode analisis deskriptif dengan bahasa pemrograman Python untuk memproses data dan pembuatan algoritma. Penggunaan metode analisis deskriptif karena penelitian ini bertujuan untuk mendapatkan informasi yang baru dari data yang ada.
3. Waktu dan tempat penelitian:
 - Waktu penelitian: Januari 2024 hingga Juni 2024
 - Tempat penelitian: Fasilitas Laboratorium Jaringan Komputer, rumah penulis.
4. Populasi dan sampel: Populasi penelitian ini adalah MPD aktif yang diperoleh dari kerja sama tim riset dengan salah satu perusahaan telekomunikasi di Indonesia. Dataset yang tersedia berkisar antara bulan Oktober 2021 hingga Juni 2022.
5. Variabel dan hipotesis: Variabel bebas dari penelitian ini adalah dataset MPD aktif pada bulan Januari dan Februari 2022, sedangkan variabel terikat pada penelitian ini adalah hasil rekonstruksi rute perjalanan pengguna, pola kecepatan dan arus lalu lintas, serta evaluasi hasil identifikasi pola kecepatan dan arus lalu lintas menggunakan MPD aktif di Jalan Malioboro.
6. Hipotesis: Hipotesis yang diajukan adalah MPD aktif dapat dimanfaatkan untuk

mengidentifikasi pola kecepatan dan arus lalu lintas di Jalan Malioboro dengan memanfaatkan hasil rekonstruksi rute perjalanan pengguna.

7. Keterbatasan Penelitian:

- Penulis serta perusahaan telekomunikasi yang memberikan data tidak memiliki pengetahuan terkait cara pencuplikan MPD aktif.
- Data penelitian yang digunakan terbatas, hanya mencakup bulan Januari hingga Februari 2022.
- Komputer yang digunakan untuk pemrosesan data berlokasi di lingkup jaringan internet Universitas Gadjah Mada (UGM).

1.5 Manfaat Penelitian

Hasil penelitian ini diharapkan dapat memberikan manfaat untuk:

1. Pembuat kebijakan, dalam merumuskan kebijakan sistem transportasi yang lebih efektif dan efisien. Dengan memanfaatkan MPD aktif untuk mengidentifikasi pola kecepatan dan arus lalu lintas, pembuat kebijakan dapat meningkatkan efisiensi dan efektivitas pengambilan data kondisi lalu lintas. Peningkatan ini diharapkan dapat membantu pemerintah dalam mengatasi masalah kemacetan lalu lintas di Indonesia yang semakin kompleks.
2. Peneliti di bidang transportasi, dalam mengembangkan penelitian lebih lanjut terkait analisis kecepatan dan arus lalu lintas. Penelitian ini diharapkan dapat menjadi referensi pendukung bagi pengembangan ilmu pengetahuan dan teknologi di bidang transportasi, khususnya dalam pemanfaatan data MPD aktif untuk analisis lalu lintas. Penelitian ini diharapkan dapat menjadi acuan untuk pengembangan lebih lanjut dengan menggunakan dataset atau metode lain.

1.6 Sistematika Penulisan

Bab I membahas mengenai pendahuluan yang terdiri dari latar belakang penelitian yang mendasari dilakukannya penelitian. Selain itu, bab ini juga berisi rumusan masalah, tujuan penelitian, batasan penelitian, dan manfaat penelitian.

Bab II membahas mengenai tinjauan pustaka yang berisi kajian literatur yang relevan dengan penelitian yang dilakukan. Selain itu, bab ini juga mencakup dasar teori yang berisi konsep-konsep dasar yang digunakan dalam penelitian.

Bab III membahas mengenai metode penelitian yang digunakan dalam penelitian ini. Teknik analisis seperti algoritma, alur penelitian, serta perhitungan matematis yang digunakan dalam penelitian dijelaskan di bab ini.

Bab IV membahas mengenai hasil penelitian yang diperoleh dari analisis data

yang telah dilakukan. Hasil penelitian yang ditemukan kemudian dianalisis sehingga dapat diambil jawaban yang tepat untuk menjawab rumusan masalah.

Bab V membahas mengenai kesimpulan dan saran yang dapat diambil dari hasil penelitian yang telah dilakukan. Selain itu, pada bab ini penulis juga memberikan saran yang dapat dilakukan untuk penelitian selanjutnya.

BAB II

TINJAUAN PUSTAKA DAN DASAR TEORI

2.1 Tinjauan Pustaka

Penelitian terkait identifikasi pola kecepatan dan arus lalu lintas menggunakan MPD aktif dengan data GPS telah terbukti berhasil menghasilkan informasi yang relevan dalam menggambarkan pola lalu lintas. Salah satu penelitian yang dilakukan oleh Wang *et al.* [1] berfokus pada analisis visual kemacetan lalu lintas di perkotaan menggunakan data GPS dari perjalanan taksi. Masalah utama yang diteliti adalah kompleksitas dan ketidakpastian dalam memprediksi dan memahami pola kemacetan lalu lintas yang dinamis dan saling terkait. Untuk mengatasi masalah ini, Wang *et al.* mengembangkan sistem interaktif untuk analisis visual kemacetan lalu lintas yang dapat melakukan perhitungan secara otomatis dan *real-time* menggunakan data GPS perjalanan taksi. Data yang digunakan dalam penelitian ini adalah data GPS dari 28.519 taksi di Beijing yang mencakup 24 hari, menghasilkan 379.107.927 titik sampel.

Proses pertama dilakukan dengan *data cleaning*, termasuk pembersihan data GPS untuk menghilangkan kesalahan dan data yang tidak relevan, serta pemrosesan jaringan jalan untuk memastikan kualitas data jaringan jalan. Proses *cleaning* terdiri dari beberapa tahap meliputi eliminasi koordinat di luar target analisis, eliminasi duplikat berdasarkan *timestamp*, dan eliminasi kecepatan yang tidak realistis. Selain itu, data yang digunakan termasuk pada data GPS yang memiliki frekuensi *sampling* rendah, dengan rata-rata frekuensi *sampling* sebesar 3 menit antar point. Penggunaan data dengan frekuensi rendah ini memerlukan jarak dan waktu yang lebih relevan untuk memastikan akurasi interpolasi. Dengan demikian, dilakukan eliminasi data dengan jarak lebih dari 2 km, serta eliminasi data dengan jarak waktu antar point lebih dari 10 menit.

Metode *cleaning* selanjutnya terdiri dari eliminasi lokasi taksi berhenti yang tidak mencerminkan kondisi lalu lintas, seperti parkir dan berhenti sejenak untuk menunggu penumpang. Metode *cleaning* terakhir adalah menghilangkan perjalanan yang pendek, dimana lintasan tersebut hanya memiliki maksimal 5 titik data atau jaraknya kurang dari 500 meter, hal ini dilakukan untuk setiap proses yang telah dilakukan untuk meningkatkan akurasi analisis.

Setelah data selesai dilakukan proses pembersihan, dilakukan proses *map matching* untuk mencocokkan data GPS dengan jaringan jalan. Pada studi ini digunakan algoritma ST-matching, dimana algoritma ini cocok untuk data GPS dengan frekuensi *sampling* rendah. Algoritma ini mempertimbangkan waktu dan jarak antar titik data, serta arah perjalanan untuk mencocokkan data GPS dengan jaringan jalan yang sesuai. Akan tetapi, karena keterbatasan data kecepatan pendukung, studi ini hanya menerapkan

algoritma S-matching. Arah perjalanan juga dipertimbangkan dalam analisis ini, dengan melihat posisi dari titik data GPS yang berdekatan dalam urutan waktu. Hal ini penting karena studi ini menggunakan satuan *dWay* (*directed way*) sebagai satuan spasial segmen jalan, dimana setiap *dWay* memiliki satu atau lebih jalur dengan arah yang berbeda.

Berikutnya, dilakukan perhitungan kecepatan untuk setiap satuan *time bin* sebesar 10 menit di setiap *dWay*, dimana kecepatan dihitung berdasarkan jarak dan waktu antar titik data untuk setiap *trajectory* atau lintasan taksi yang melewati segmen jalan tersebut. Rata-rata kecepatan keseluruhan kemudian dihitung berdasarkan rata-rata kecepatan dari semua *trajectory* taksi yang melewati segmen jalan untuk setiap *time bin* sebesar 10 menit. Setelah itu, dilakukan pendeteksian kemacetan pada setiap *dWay* dengan menetapkan batasan tertentu sebagai ambang penentuan terjadinya kemacetan. Metode ini kemudian menjadi bahan untuk pembuatan sistem interaktif visualisasi yang menampilkan pola kemacetan lalu lintas di Beijing secara *real-time*.

Visualisasi yang dihasilkan berupa *pixel map view* dengan setiap pixel merepresentasikan satuan *time bin* 10 menit pada setiap segmen *dWay*. Nilai warna dari setiap piksel menunjukkan tingkat kecepatan pada segmen jalan tersebut, dengan warna merah menunjukkan kecepatan rendah dan warna hijau menunjukkan kecepatan tinggi. Visualisasi ini cukup detail sehingga memungkinkan pengguna untuk memahami pola kemacetan lalu lintas dengan lebih baik.

Dari penelitian yang dilakukan oleh Wang *et al.* [1] keunggulannya ada pada penggunaan beberapa metode *filtering* yang lengkap dan sistematis untuk memastikan kualitas data yang digunakan. Selain itu, penyajian visualisasi *pixel map* yang detail pada setiap waktunya memungkinkan pengguna untuk memahami pola kemacetan lalu lintas dengan lebih baik. Akan tetapi, penelitian ini juga memiliki keterbatasan, salah satunya ketergantungan pada kualitas data GPS dan jaringan jalan. Meskipun karakteristik data yang digunakan adalah data GPS dengan frekuensi *sampling* rendah, tetapi data perjalanan yang didapatkan cukup banyak, serta sumber data taksi yang digunakan sudah berada di jalan. Karakteristik data ini memungkinkan metode *cleaning* pada studi ini belum mempertimbangkan penggunaan metode *filtering* untuk melakukan eliminasi data yang berada di luar ruas jalan. Kekurangan ini juga termasuk penggunaan metode *map matching* yang lebih cocok untuk data-data yang berada dekat atau bahkan di dalam ruas jalan. Selain itu, terdapat pula potensi kesulitan dalam mengatur parameter filter dalam *preprocessing* yang tepat untuk memastikan hasil yang akurat.

Dataset MPD aktif yang digunakan penulis dalam penelitian ini memiliki karakteristik frekuensi *sampling* yang rendah, dimana hal ini dapat mempengaruhi akurasi dan ketepatan hasil analisis yang dilakukan. Selain itu, MPD aktif bukan data yang dihasilkan melalui perjalanan suatu individu yang terkhusus pada segmen jalan, melainkan data yang dihasilkan dari perangkat GPS yang terpasang pada telepon seluler pengguna, se-

hingga data yang dihasilkan mungkin tidak selalu berkontribusi pada kondisi lalu lintas. Karakteristik tersebut menjadi tantangan dalam implementasi rekonstruksi rute perjalanan pengguna dengan MPD aktif, sehingga dibutuhkan penelitian sejenis yang berfokus pada pengembangan metode untuk merekonstruksi rute perjalanan dari data GPS dengan karakteristik yang serupa, yaitu frekuensi *sampling* rendah serta jenis data yang didapatkan dari telepon seluler pengguna. Oleh karena itu, penelitian yang dilakukan oleh Rakhman *et al.* [9] menjadi relevan untuk dijadikan acuan dalam penelitian ini.

Rakhman *et al.* [9] melakukan penelitian dengan fokus masalah pada tantangan dalam merekonstruksi jalur pergerakan dari dataset GPS yang memiliki frekuensi *sampling* rendah, dimana hal ini kerap terjadi karena keterbatasan kapasitas penyimpanan atau biaya transmisi data. Data yang digunakan pun diperoleh dari data GPS yang dikumpulkan dari perangkat GPS yang terpasang pada telepon seluler pengguna, dimana serupa dengan karakteristik data MPD aktif yang digunakan penulis dalam penelitian ini. Data yang digunakan dalam penelitian ini adalah data mobilitas historis individu dari November 2021 hingga Juni 2022, yang terdiri dari titik-titik GPS dengan empat kolom utama: ID pengguna yang terenkripsi, koordinat *latitude*, koordinat *longitude*, dan *timestamp*.

Proses pengolahan data dimulai dengan proses *preprocessing data* pada data mentah yang pertama kali dilakukan proses transformasi kolom untuk mengambil atribut yang relevan, eliminasi data duplikat, serta konversi data *timestamp* ke format *datetime* yang sesuai. Selanjutnya dilakukan proses pada data jaringan jalan untuk membuat *graph*, yang mana *graph* ini nantinya akan digunakan dalam proses selanjutnya yang melibatkan penggunaan jaringan jalan. Proses tersebut yaitu *map matching*, dimana data GPS yang diperoleh akan dipetakan ke jaringan jalan terdekat. Proses ini dilakukan dengan menggunakan algoritma KD-Tree, dengan cara membagi ruang dua dimensi jaringan jalan menjadi area-area yang lebih kecil, masing-masing mewakili segmen jalan, dan menetapkan titik-titik GPS ke segmen jalan terdekat dengan efisien.

Selanjutnya dilakukan pula eliminasi titik-titik data yang menunjukkan lokasi diam (*immobility*) untuk mengurangi beban komputasi. Filter ini bekerja dengan mengecek titik-titik yang berada pada lokasi yang sama dalam jangka waktu tertentu. Jika titik-titik tersebut berada pada lokasi yang sama dalam jangka waktu tertentu, maka titik-titik tersebut akan dihapus. Hal ini dilakukan untuk mengurangi volume data yang harus disimpan dan diproses, serta mengurangi beban komputasi yang diperlukan dalam proses selanjutnya.

Rekonstruksi jalur atau *path reconstruction* kemudian dilakukan, dimana langkah ini melibatkan penambahan titik-titik koordinat baru berdasarkan algoritma *shortest path A** untuk memperkirakan jalur yang paling mungkin diambil antara titik-titik GPS yang berdekatan. Jalur yang diperkirakan ini kemudian digunakan sebagai dasar untuk rekon-

struksi. Interpolasi waktu juga diterapkan untuk memperkirakan waktu kedatangan pada titik-titik koordinat baru yang ditambahkan selama proses rekonstruksi jalur. Waktu ini penting untuk menentukan durasi perjalanan antara dua titik GPS berturut-turut, yang kemudian digunakan untuk menentukan kecepatan perjalanan antara dua titik pada segmen jalan tertentu. Perbedaan waktu antara dua titik GPS berturut-turut dibagi dengan jumlah titik baru yang dihasilkan untuk menentukan durasi antara setiap titik baru.

Berdasarkan studi yang telah dilakukan oleh Rakhman *et al.* [9] ini menghasilkan metode pendekatan yang mampu merekonstruksi jalur pergerakan dengan data frekuensi *sampling* rendah serta data GPS yang didapatkan dari perangkat GPS yang terpasang pada telepon seluler pengguna. Penelitian ini memiliki keunggulan atas kemampuannya untuk mengurangi volume data yang harus disimpan dan diproses menggunakan *immobility filter*, dimana efektif dengan karakteristik data GPS yang memiliki frekuensi *sampling* rendah. Penggunaan algoritma KD-Tree yang cepat dan efisien juga menjadi kelebihan dari studi ini.

Akan tetapi, masih terdapat kekurangan dalam studi ini, seperti tidak adanya metode pembeda arah pada data *trajectory* yang didapatkan dari data GPS. Kekurangan lain adalah pada kurangnya penerapan metode *preprocessing* yang lebih mendalam dan detail, seperti eliminasi pada jenis *trajectory* yang tidak memenuhi syarat, misalnya *trajectory* yang pendek atau memiliki frekuensi yang terlalu lama. Secara keseluruhan, metode yang diusulkan pada studi ini menunjukkan potensi yang signifikan untuk menghasilkan rekonstruksi rute perjalanan menggunakan data GPS, terutama dengan karakteristik data yang memiliki *sampling* frekuensi rendah.

Beberapa studi tidak hanya berhenti pada hasil analisis saja, namun juga menerapkan metode prediksi seperti *machine learning* untuk memprediksi kondisi lalu lintas di masa depan. Hal ini yang dilakukan oleh Zhou *et al.* [10], membahas mengenai analisis dan prediksi aliran lalu lintas menggunakan data GPS dengan *Floating Car Data* (FCD). Penelitian ini mengembangkan model dan algoritma baru untuk memproses data GPS yang didapatkan dari mobil-mobil pelacak tersebut, yang kemudian digunakan untuk analisis dan prediksi aliran lalu lintas. Tujuannya adalah untuk mengestimasi dan memprediksi kondisi lalu lintas secara akurat dan cepat. Data yang digunakan dalam penelitian ini adalah log GPS dari lebih dari 5.000 taksi di sebuah kota selama satu bulan, yang menghasilkan sekitar 3.400 hingga 3.500 lintasan perjalanan yang valid setelah proses *filtering*.

Proses penelitian dilakukan secara sistematis dimulai dengan inisialisasi data, dimana log GPS diurutkan berdasarkan urutan waktu untuk menghasilkan lintasan yang runtut. Selanjutnya, dilakukan pemetaan lintasan perjalanan ke peta jalan (*map matching*) untuk memastikan bahwa data GPS sudah sesuai dengan jalan yang sebenarnya. Dalam tahap ini, titik-titik berhenti atau *stay points* dan titik-titik perubahan status atau *state*

switching points diidentifikasi dan dihapus untuk mengurangi gangguan data. Algoritma pemetaan peta yang digunakan didasarkan pada *buffer* dan sudut arah untuk meningkatkan akurasi pemetaan.

Setelah pemetaan peta, kecepatan rata-rata dari setiap segmen jalan dihitung menggunakan data GPS yang telah diproses. Kecepatan rata-rata ini digunakan sebagai indikator kondisi lalu lintas, menggantikan arus lalu lintas yang sulit diukur secara langsung. Prediksi aliran lalu lintas jangka pendek dilakukan menggunakan model regresi *Least Squares Support Vector Machine* (LS-SVM), yang dilatih dengan data historis untuk memprediksi perubahan aliran lalu lintas di masa depan.

Keunggulan dari penelitian ini terletak pada penggunaan algoritma eliminasi *stay locations* dan *state switching points* untuk mengurangi gangguan data sehingga meningkatkan akurasi analisis. Akan tetapi, studi ini belum mempertimbangkan penggunaan *trajectory segmentation* dalam proses *preprocessing data*, yang dapat membantu dalam mengidentifikasi *trajectory* yang relevan.

Penelitian lain yang menggunakan metode *machine learning* untuk analisis data GPS adalah penelitian oleh Kyaw *et al.* [2], dengan menggunakan data GPS dari perjalanan bus umum. Data yang digunakan dalam penelitian ini adalah data GPS yang dikumpulkan dari bus yang beroperasi di rute 21 dari sistem bus Kota Yangon, China.

Data ini mencakup informasi posisi dan waktu yang dikumpulkan secara terus-menerus. Proses penelitian dimulai dengan pengumpulan dan *preprocessing data* GPS. Langkah *preprocessing* melibatkan eliminasi fitur yang tidak diperlukan, seperti nilai kecepatan nol yang menunjukkan bus sedang parkir, serta penghapusan *outlier* yang tidak konsisten dengan kecepatan normal. Data yang telah diproses kemudian digunakan untuk analisis lebih lanjut.

Studi ini juga melakukan implementasi algoritma *map matching* untuk mencocokkan data GPS dengan peta digital jaringan jalan Kota Yangon, serta model *K-Nearest Neighbors* (KNN) untuk menentukan titik awal dan akhir segmen jalan. Setelah data GPS dipetakan ke jaringan jalan, kecepatan rata-rata untuk setiap segmen jalan dihitung berdasarkan data historis dan data GPS langsung dari bus yang sedang berjalan. Fitur-fitur terkait keterlambatan lalu lintas diekstraksi dari *Point of Interest* (POI) di sekitar segmen jalan dan digunakan dalam model estimasi kecepatan perjalanan.

Hasil penelitian oleh Kyaw *et al.* [2] menunjukkan bahwa model estimasi kecepatan perjalanan yang dikembangkan mampu memberikan estimasi kecepatan yang akurat untuk segmen-segmen jalan di rute bus 21. Keunggulan penelitian ini mencakup penggunaan data GPS yang lebih murah dan lebih mudah dianalisis dibandingkan dengan sensor jalan sisi. Namun, penelitian ini juga memiliki keterbatasan, seperti ketergantungan pada data GPS dari satu rute bus saja, yang dapat membatasi generalisasi hasil ke seluruh

jaringan jalan kota. Selain itu, tantangan dalam mengakses data langsung untuk setiap segmen jalan sepanjang waktu juga menjadi kendala, yang diatasi dengan menggabungkan jejak GPS dari beberapa bus untuk memperbarui faktor kecepatan setiap 10 menit.

Penelitian lainnya oleh Satrinia *et al.* [6] berfokus pada prediksi kecepatan lalu lintas menggunakan data GPS dari perjalanan taksi di Kota Bandung. Mereka mengembangkan sistem yang menggunakan metode *Support Vector Regression* (SVR) untuk memprediksi kecepatan lalu lintas masa depan setelah melakukan *preprocessing data* GPS guna meningkatkan akurasi. Langkah-langkah *preprocessing* meliputi impor dan penguraian data, konversi koordinat menjadi tipe data spasial, pembersihan data, dan pengelompokan titik-titik dalam satu perjalanan.

Selanjutnya, mereka melakukan *preprocessing data* peta jalan, mencakup impor data dalam format *shapefile*, pembuatan topologi jaringan jalan, dan perhitungan panjang segmen jalan. Proses *map matching* digunakan untuk memperbaiki posisi data GPS menggunakan informasi topologi, melibatkan pencarian kandidat jalan terdekat, perhitungan jarak antara titik GPS dan segmen jalan, serta penggunaan algoritma Dijkstra. Kecepatan lalu lintas dihitung dengan menggabungkan data kecepatan rata-rata setiap segmen jalan. Metode SVR kemudian diterapkan untuk memprediksi kecepatan lalu lintas di masa depan berdasarkan data historis yang telah diproses. Hasilnya menunjukkan bahwa metode *map matching* meningkatkan akurasi data dan SVR efektif dalam prediksi dengan parameter akurasi *Mean Average Error* (MAE) dan *Mean Squared Error* (MSE) yang rendah, meski parameter kernel SVR masih memerlukan pengujian lebih lanjut.

Tidak hanya identifikasi kecepatan lalu lintas, pada penelitian ini penulis juga mengidentifikasi arus lalu lintas berdasarkan MPD aktif. Riset yang dilakukan oleh Tramontana *et al.* [11] berfokus pada analisis data GPS untuk mengidentifikasi aliran (*flow*) dan arus aliran (*flow density*) pada segmen jalan. Metode yang digunakan melibatkan beberapa langkah sistematis untuk memproses dan menganalisis data GPS yang dikumpulkan dari perangkat *mobile*. Pertama, data GPS yang terdiri dari *latitude*, *longitude*, dan *timestamp* dari setiap pengguna diurutkan berdasarkan *timestamp* untuk membentuk lintasan. Setiap lintasan kemudian dibersihkan dari *outlier* dan *noise* untuk memastikan data yang lebih homogen.

Setelah data dibersihkan, algoritma analisis data diterapkan untuk mengidentifikasi lintasan yang paling sering digunakan oleh pengguna. Algoritma ini menghitung jumlah pengguna yang melewati lintasan yang sama dalam interval waktu yang telah ditentukan. Untuk setiap lintasan yang diidentifikasi sebagai aliran, jumlah pengguna yang melewati lintasan tersebut dihitung pada setiap slot waktu yang telah didefinisikan, yang dibagi menjadi enam interval, dimana masing-masing interval memiliki durasi empat jam, mulai dari tengah malam hingga pukul 23:59.

Selain menghitung jumlah pengguna, penelitian ini juga menghitung kecepatan rata-rata pengguna pada setiap lintasan. Kecepatan ini dihitung dengan membagi jarak yang ditempuh (dalam meter) dengan waktu yang dibutuhkan (selisih antara *timestamp* pertama dan terakhir dari lintasan). Hasil dari analisis ini memberikan informasi penting tentang arus aliran dan kecepatan lalu lintas rata-rata pada berbagai segmen jalan, yang dapat digunakan untuk mengidentifikasi area dengan kecepatan rendah atau kemacetan, serta untuk merencanakan perbaikan transportasi publik. Hasil penelitian menunjukkan bahwa metode yang diusulkan berhasil mengidentifikasi 25 aliran yang melibatkan lebih dari 10% pengguna, dan beberapa jalur yang melibatkan lebih dari 30% pengguna.

Hasil analisis data diperlukan perlu untuk dievaluasi untuk memastikan akurasi-nya, sehingga perlu dilakukan validasi terhadap hasil analisis dengan membandingkan hasil analisis dengan data *ground truth* yang berasal dari sumber lain. Penelitian oleh Wang *et al.* [12] memprediksi aliran lalu lintas truk menggunakan data GPS yang diambil secara sampel, dengan menggunakan metode *Long Short Term Memory* (LSTM) dan *Gated Recursive Unit* (GRU). Penelitian ini terdiri dari dua fase utama, yaitu ekspansi data dan prediksi. Dalam fase ekspansi data, metode koefisien konstan sepotong-sepotong digunakan untuk meminimalkan kesalahan antara aliran truk yang diambil sampelnya dan aliran truk aktual. Dalam fase prediksi, metode LSTM dan GRU digunakan untuk meningkatkan akurasi prediksi.

Untuk memverifikasi akurasi prediksi aliran lalu lintas truk, hasil prediksi dibandingkan dengan data aliran lalu lintas aktual yang diperoleh dari survei lalu lintas manual. Survei ini dilakukan pada 46 segmen jalan untuk mendapatkan data aliran truk yang sebenarnya. Data survei lalu lintas ini mencakup informasi seperti tanggal survei, slot waktu, nomor stasiun survei, jarak tempuh, arah perjalanan, dan aliran truk aktual. Data survei ini dianggap sebagai *ground truth* atau data referensi yang paling mendekati kondisi sebenarnya.

Akurasi prediksi pada penelitian ini menggunakan beberapa metrik evaluasi, termasuk *Root Mean Squared Error* (RMSE), *Mean Absolute Error* (MAE), *Mean Absolute Percentage Error* (MAPE), dan *Explained Variance Score* (EVS). Hasil evaluasi menunjukkan bahwa model LSTM dan GRU memiliki kinerja yang lebih baik dibandingkan dengan model tradisional seperti SVR dan *AutoRegressive Integrated Moving Average* (ARIMA) dalam memprediksi aliran lalu lintas truk.

Penelitian dalam tugas akhir ini bertujuan untuk mengidentifikasi pola kecepatan dan arus lalu lintas di ruas Jalan Malioboro menggunakan MPD aktif. Metode yang digunakan adalah analisis deskriptif dengan merekonstruksi rute perjalanan pengguna dari data GPS yang diperoleh. Penelitian ini serupa dengan apa yang dilakukan oleh Wang *et al.* [1], hanya saja penulis tidak sampai pada pembuatan sistem interaktif, melainkan fokus pada identifikasi pola lalu lintas hingga tahap visualisasi. Selain itu, data yang di-

gunakan oleh penulis tidak berasal dari log GPS kendaraan, melainkan MPD aktif yang diperoleh dari pengguna operator seluler. Oleh karena itu, penelitian yang dilakukan oleh Rakhman *et al.* [9] juga menjadi relevan untuk dijadikan acuan dalam penelitian ini. Hal ini dikarenakan metode yang digunakan dalam penelitian ini melibatkan proses *preprocessing data*, *map matching*, dan rekonstruksi rute perjalanan dari data GPS yang memang diperuntukkan untuk karakteristik data yang memiliki frekuensi *sampling* rendah serta jenis data *non-stationer* yang tidak selalu berada di jalan seperti MPD aktif. Peningkatan dari segi metode yang dilakukan oleh penulis adalah dengan menggabungkan metode *preprocessing data* yang dilakukan oleh Rakhman *et al.* dan Wang *et al.*, serta melakukan beberapa modifikasi terhadap pendekatan yang digunakan.

Hasil analisis yang akan didapatkan dari penelitian ini pun serupa dengan Wang *et al.* dimana menghasilkan pola lalu lintas di suatu ruas jalan dalam bentuk visualisasi grafis, yang kemudian dari visualisasi tersebut dapat ditarik interpretasi kondisi lalu lintas jalan dari waktu ke waktu. Di samping itu, penelitian ini juga akan menghasilkan informasi pola arus lalu lintas, serupa dengan apa yang dilakukan oleh Tramontana *et al.* [11], yang mana hal ini tidak dilakukan oleh Wang. Penulis melakukan evaluasi pada temuan pola dengan melakukan perbandingan dengan data *ground truth*, dalam hal ini terinspirasi oleh penelitian yang dilakukan oleh Wang *et al.* [12] yang melakukan validasi hasil analisis dengan data survei lalu lintas manual untuk memastikan akurasi hasil analisis yang dilakukan. Perbandingan penelitian terdahulu secara lebih lengkap ditampilkan pada Tabel 2.1.

Tabel 2.1. Ringkasan perbandingan penelitian terdahulu

Peneliti	Data	Metode	Hasil
Wang <i>et al.</i> (2013) [1]	Data GPS dari 28.519 taksi di Beijing selama 24 hari (379.107.927 titik sampel)	- <i>Data cleaning</i> (eliminasi titik di luar target, duplikat, kecepatan tidak realistis, eliminasi data dengan jarak >2km, eliminasi titik saat taksi berhenti, eliminasi data dengan jarak waktu antar titik >10 menit) - <i>Map matching</i> menggunakan algoritma ST-matching - Perhitungan kecepatan per 10 menit pada setiap segmen jalan	- Sistem interaktif untuk analisis visual kemacetan lalu lintas secara <i>real-time</i> - Visualisasi <i>pixel map view</i> untuk memahami pola kemacetan lalu lintas
Rakhman <i>et al.</i> (2023) [9]	Data GPS dari perangkat telepon seluler pengguna (Nov 2021 - Jun 2022)	- <i>Preprocessing</i> (transformasi kolom, eliminasi duplikat, konversi <i>timestamp</i>) - <i>Map matching</i> menggunakan algoritma KD-Tree - Implementasi filter <i>immobility</i> - Rekonstruksi rute perjalanan menggunakan algoritma <i>shortest path</i> A* - Interpolasi waktu untuk estimasi waktu di titik koordinat baru	- Metodologi untuk merekonstruksi jalur perjalanan dari dataset GPS frekuensi rendah

Peneliti	Data	Metode	Hasil
Zhou <i>et al.</i> (2013) [10]	Log GPS dari lebih dari 5.000 taksi selama satu bulan, dengan 3.400-3.500 lintasan perjalanan yang valid	- Inisialisasi data, log GPS diurutkan berdasarkan urutan waktu untuk menghasilkan lintasan perjalanan GPS - Eliminasi titik data <i>immobility</i> - Pemetaan titik GPS ke peta jalan (<i>map matching</i>) untuk memastikan data GPS sesuai dengan jalan yang sebenarnya - Prediksi aliran lalu lintas menggunakan algoritma LS-SVM	- Model dan algoritma baru untuk analisis dan prediksi aliran lalu lintas - Estimasi kondisi lalu lintas
Kyaw <i>et al.</i> (2018) [2]	Data GPS dari bus umum di rute 21 sistem bus kota Yangon	- <i>Preprocessing</i> (eliminasi fitur tidak diperlukan, penghapusan <i>outlier</i>) - <i>Map matching</i> - Model prediksi kecepatan dengan <i>K-Nearest Neighbors</i> (KNN) - Estimasi kecepatan rata-rata untuk setiap segmen jalan - Ekstraksi fitur-fitur terkait keterlambatan lalu lintas dari <i>Point of Interest</i> (POI) di sekitar segmen jalan	- Model estimasi kecepatan perjalanan - Ketergantungan pada data GPS dari satu rute bus yang membatasi generalisasi hasil ke seluruh jaringan jalan kota - Tantangan dalam mengakses data langsung untuk setiap segmen jalan sepanjang waktu diatasi dengan menggabungkan jejak GPS dari beberapa bus untuk memperbarui faktor kecepatan setiap 10 menit

Peneliti	Data	Metode	Hasil
Satrinia <i>et al.</i> (2017) [6]	Data GPS dari perjalanan taksi di Kota Bandung	- <i>Support Vector Regression</i> (SVR) untuk prediksi kecepatan lalu lintas - <i>Preprocessing data</i> GPS (impor dan parsing data, konversi koordinat menjadi tipe data spasial, pembersihan data, pengelompokan titik-titik dalam satu perjalanan) - <i>Preprocessing data</i> peta jalan (impor data <i>shapefile</i>, pembuatan topologi jaringan jalan, perhitungan panjang segmen jalan) - <i>Map matching</i> (pencarian kandidat jalan terdekat, perhitungan jarak antara titik GPS dan segmen jalan, penggunaan algoritma Dijkstra) - Perhitungan kecepatan lalu lintas dengan menggabungkan data kecepatan rata-rata setiap segmen jalan	- <i>Map matching</i> meningkatkan akurasi data - SVR efektif dalam prediksi dengan nilai MAE dan MSE yang rendah - Parameter kernel SVR memerlukan pengujian lebih lanjut
Tramontana <i>et al.</i> (2018) [11]	Data GPS dari perangkat <i>mobile</i>	- Analisis data GPS untuk mengidentifikasi aliran (<i>flow</i>) dan arus aliran (<i>flow density</i>) - Pengurutan data GPS berdasarkan <i>timestamp</i> untuk membentuk lintasan - Pembersihan lintasan dari <i>outlier</i> dan <i>noise</i> - Algoritma analisis data untuk mengidentifikasi lintasan yang paling sering digunakan - Penghitungan jumlah pengguna yang melewati lintasan yang sama dalam interval waktu tertentu - Penghitungan kecepatan rata-rata pengguna pada setiap lintasan	- Mengidentifikasi 25 aliran yang melibatkan lebih dari 10% pengguna - Beberapa jalur melibatkan lebih dari 30% pengguna - Informasi tentang arus aliran dan kecepatan rata-rata pada berbagai segmen jalan

Peneliti	Data	Metode	Hasil
Wang <i>et al.</i> (2020) [12]	Data GPS dari truk di jaringan jalan	- Ekspansi data dengan metode koefisien konstan sepotong-sepotong untuk meminimalkan kesalahan antara aliran truk yang diambil sampelnya dan aliran truk aktual - Prediksi dengan algoritma <i>Long Short Term Memory</i> (LSTM) dan <i>Gated Recursive Unit</i> (GRU) untuk meningkatkan akurasi prediksi - Validasi hasil prediksi dengan data survei lalu lintas manual pada 46 segmen jalan	- LSTM dan GRU memiliki kinerja lebih baik dibandingkan model tradisional seperti SVR dan ARIMA - Akurasi prediksi LSTM lebih tinggi 4.1% dibandingkan GRU - Urutan prediksi sebelum ekspansi lebih akurat 8.26% dibandingkan ekspansi sebelum prediksi

2.2 Dasar Teori

2.2.1 Kecepatan Lalu Lintas

Kecepatan lalu lintas adalah salah satu parameter penting dalam analisis lalu lintas yang mencerminkan seberapa cepat kendaraan bergerak di sepanjang jalan tertentu. Berdasarkan Pedoman Kapasitas Jalan Indonesia (PKJI) 2023, kecepatan lalu lintas didefinisikan sebagai jarak yang dapat ditempuh oleh kendaraan dalam satu satuan waktu, yang biasa dinyatakan dalam satuan km/jam [3]. Terdapat dua cara untuk mengukur kecepatan rata-rata lalu lintas, yaitu dengan menghitung kecepatan rata-rata waktu, atau *Time Mean Speed* (TMS), dan kecepatan rata-rata ruang, atau *Space Mean Speed* (SMS) [13]. Kecepatan rata-rata waktu adalah kecepatan rata-rata kendaraan yang melewati titik tertentu dalam periode waktu tertentu, sedangkan rata-rata ruang adalah kecepatan rata-rata kendaraan yang melewati segmen jalan tertentu dalam periode waktu tertentu [14]. Perhitungan masing-masing metode menggunakan persamaan berikut [13]:

1. Kecepatan Rata-Rata Waktu (*Time Mean Speed*)

$$TMS = \frac{\sum \frac{d}{t_i}}{n} \quad (2-1)$$

2. Kecepatan Rata-Rata Ruang (*Space Mean Speed*)

$$SMS = \frac{d}{\sum \frac{t_i}{n}} = \frac{nd}{\sum t_i} \quad (2-2)$$

Keterangan:

- d = jarak tempuh (meter)
- n = jumlah kendaraan
- t_i = waktu tempuh kendaraan ke- i

Saat ini, perhitungan kecepatan lalu lintas di Indonesia diatur dalam Panduan Survei dan Perhitungan Waktu Perjalanan Lalu Lintas (No.001/T/BNKT/1990) [15]. Secara umum, metode survei dapat dibagi menjadi metode manual dan digital. Metode manual melibatkan penghitungan kecepatan oleh surveyor yang mengamati dan mencatat waktu tempuh kendaraan di titik tertentu, sedangkan metode digital menggunakan peralatan elektronik, seperti radar atau loop induktif, untuk mengukur kecepatan kendaraan secara otomatis. Metode digital lebih akurat dan efisien dibandingkan metode manual, namun memerlukan biaya dan peralatan khusus [15].

Kecepatan lalu lintas dipengaruhi oleh berbagai faktor yang dapat dikategorikan ke dalam aspek fisik, psikologis, dan kondisi lalu lintas. Studi menunjukkan bahwa geo-

metri jalan, seperti tikungan dan jarak pandang, sangat mempengaruhi pilihan kecepatan pengemudi, di mana tikungan tajam dan jarak pandang terbatas cenderung mengurangi kecepatan kendaraan [16]. Faktor psikologis, seperti persepsi risiko dan norma sosial, mempengaruhi perilaku pengemudi dalam mematuhi batas kecepatan [17]. Kondisi lalu lintas, seperti arus dan jenis kendaraan yang melintas, juga mempengaruhi kecepatan [16]. Secara keseluruhan, kombinasi dari faktor-faktor ini menciptakan variasi kecepatan yang signifikan di berbagai segmen jalan, yang mempengaruhi kondisi lalu lintas [18].

2.2.2 Arus Lalu Lintas

Arus lalu lintas adalah jumlah kendaraan bermotor yang melewati suatu segmen jalan per jam, dengan satuan kendaraan per jam (kend/jam) atau satuan mobil penumpang per jam (SMP/jam) [3]. Volume lalu lintas, di sisi lain, merujuk pada jumlah kendaraan bermotor yang melalui suatu titik pada suatu segmen jalan dalam satuan waktu tertentu [3]. Sementara arus lalu lintas selalu dihitung dalam satuan waktu per jam, volume lalu lintas dapat dihitung dalam berbagai rentang waktu, misalnya per menit, per jam, atau per hari, tergantung pada konteks pengukuran.

Untuk mengukur arus lalu lintas, perlu dilakukan survei untuk mendapatkan data yang akurat dan representatif. Menurut dokumen Pedoman Perencanaan Survei Jalan Luar Kota [15], terdapat beberapa metode survei yang dapat digunakan, antara lain:

1. Survei Manual, menggunakan surveyor untuk menghitung arus lalu lintas di suatu segmen jalan, survey ini membutuhkan waktu dan biaya tenaga kerja yang relatif tinggi. Tantangan yang dihadapi dalam survei manual adalah keakuratan penghitungan yang sangat bergantung pada surveyor.
2. Survei Mekanis, survei yang mempergunakan peralatan mekanis, elektronis, atau digital untuk menghitung arus lalu lintas. Contoh peralatan yang digunakan adalah tabung pneumatik, loop induktif, gelombang inframerah/ultrasonik, dan kamera video.

Arus lalu lintas memiliki hubungan terhadap kecepatan kendaraan di jalan, ketika arus lalu lintas bertambah maka kecepatan rata-rata akan berkurang hingga volume maksimum tercapai [19].

2.2.3 Mobile Positioning Data (MPD)

Mobile Positioning Data (MPD) adalah data yang berkaitan dengan penggunaan ponsel dan mencakup informasi lokasi dari pengguna ponsel yang dikumpulkan oleh operator jaringan seluler (*Mobile Network Operator*, MNO) [8]. MPD dapat dibagi menjadi dua jenis utama, yaitu data MPD aktif dan pasif. Data MPD aktif diperoleh melalui

permintaan langsung ke perangkat ponsel untuk menentukan lokasinya, biasanya menggunakan teknologi sinyal radio atau GPS serta memerlukan izin dari pemilik ponsel.

Data posisi pasif dikumpulkan secara otomatis oleh operator jaringan seluler tanpa interaksi langsung dengan pengguna, biasanya melalui catatan detail panggilan (*Call Detail Records*, CDR) atau catatan detail data (*Data Detail Records*, DDR) yang mencatat aktivitas seperti panggilan, SMS, dan penggunaan internet [8] [7].

Tabel 2.2. Kolom fitur MPD aktif [20]


Tipe Informasi	Deskripsi
<i>Timestamp</i>	Tanggal dan waktu titik data diambil.
<i>Latitude</i>	Koordinat garis bujur lokasi perangkat saat titik data diambil.
<i>Longitude</i>	Koordinat garis lintang lokasi perangkat saat titik data diambil.
<i>ID</i>	Nomor identifikasi unik untuk penanda perangkat. Perangkat sama memiliki ID yang sama.

Keuntungan menggunakan MPD aktif adalah penggunaan GPS yang memungkinkan pelacakan lokasi yang sangat presisi, tetapi memerlukan partisipasi aktif dari pengguna dan dapat menguras baterai ponsel dengan cepat [21]. Di sisi lain, MPD pasif diperoleh dari data yang sudah ada dalam sistem MNO tanpa interaksi langsung dengan pengguna, sehingga lebih mudah diakses dan tidak mengganggu pengguna, meskipun akurasi lebih rendah dibandingkan dengan data GPS [8]. Hubungan antara MPD aktif dan GPS sangat erat, karena GPS sering digunakan dalam pengumpulan data posisi aktif untuk memberikan informasi lokasi yang lebih tepat dan *real-time*.

2.2.4 Map Matching

Map matching adalah teknik yang digunakan untuk menyelaraskan data posisi dari perangkat pelacakan, seperti GPS, dengan peta jalan yang mendasarinya [22]. Teknik ini penting untuk berbagai aplikasi berbasis lokasi, seperti navigasi, pelacakan kendaraan, pembaruan peta, dan pengawasan lalu lintas. *Map matching* membantu mengoreksi kesalahan posisi yang disebabkan oleh ketidakakuratan sistem penentuan posisi, sehingga memungkinkan identifikasi rute perjalanan yang lebih akurat [22].

Pentingnya *map matching* terletak pada kemampuannya untuk meningkatkan akurasi data lokasi, yang sangat penting untuk aplikasi yang memerlukan informasi posisi yang tepat [24]. Tanpa *map matching*, data GPS yang mentah dapat menunjukkan posisi yang salah karena berbagai faktor seperti *multipath*, kehilangan sinyal, atau kesalahan perangkat. Dengan menyelaraskan data ini dengan peta jalan yang akurat, *map matching* membantu mengurangi kesalahan ini dan memberikan representasi yang lebih akurat dari rute perjalanan [25].



Gambar 2.1. Contoh ilustrasi proses *map matching* [23]

Data yang digunakan dalam *map matching* biasanya mencakup data lintasan dari perangkat GPS yang terdiri dari lokasi dan *timestamp*, serta data jaringan jalan dari peta digital. Langkah-langkah umum dalam proses *map matching* meliputi pengumpulan data lintasan, identifikasi kandidat jalan yang mungkin dilalui berdasarkan data lintasan, perhitungan kesesuaian antara lintasan dan kandidat jalan, dan pemilihan jalan yang paling sesuai dengan lintasan berdasarkan kriteria tertentu seperti jarak terpendek atau probabilitas tertinggi [26].

2.2.5 *K-Dimensional Tree (KDTree)*

KDTree, atau k-dimensional tree, adalah struktur data partisi ruang yang digunakan untuk mengorganisir titik-titik dalam ruang berdimensi k [27]. Setiap node dalam KDTree mewakili titik berdimensi k, dan setiap node non-daun bertindak sebagai *hyperplane* yang membagi ruang menjadi dua bagian. *Hyperplane* ini tegak lurus terhadap salah satu sumbu dimensi, dan pemilihan sumbu dilakukan secara bergantian pada setiap tingkat pohon. KDTree sangat berguna untuk pencarian tetangga terdekat (*nearest neighbor search*) dan pencarian dalam rentang tertentu (*range search*) dalam ruang multidimensi [27].

Dalam penerapan *map matching*, KDTree digunakan untuk mencocokkan titik-titik GPS dengan jaringan jalan yang ada. Proses ini melibatkan pencarian titik-titik terdekat pada peta yang sesuai dengan titik-titik GPS yang diukur. KDTree membantu mempercepat proses ini dengan mengurangi kompleksitas pencarian secara linear, sehingga memungkinkan pemetaan yang lebih cepat dan akurat [9]. Langkah-langkah umum dalam penerapan KDTree untuk *map matching* dimulai dari membangun KDTree dari titik-titik pada jaringan jalan, untuk setiap titik GPS dicari titik terdekat pada KDTree, dan memperbarui posisi titik GPS berdasarkan hasil pencarian tersebut [28].

2.2.6 Hidden Markov Model (HMM)

Hidden Markov Model (HMM) adalah model statistik yang digunakan untuk memodelkan sistem yang memiliki proses tersembunyi (*hidden states*) yang tidak dapat diamati secara langsung, tetapi dapat diperkirakan melalui observasi yang dapat diamati [29]. HMM terdiri dari dua komponen utama, yaitu *transition probabilities* yang menggambarkan kemungkinan transisi antar state tersembunyi, dan *emission probabilities* yang menggambarkan kemungkinan observasi yang dihasilkan dari state tersembunyi tertentu.

Salah satu pemanfaatan HMM adalah pada proses *map matching*. HMM digunakan untuk memodelkan urutan segmen jalan (*state*) dan titik GPS yang diamati (*emission*). Dalam konteks ini, probabilitas transisi mewakili kemungkinan berpindah dari satu segmen jalan ke segmen jalan lainnya, sedangkan probabilitas emisi mewakili kemungkinan memproyeksikan titik GPS tertentu pada segmen jalan tertentu. Persamaan matematis dari HMM untuk implementasi *map matching* dapat dinyatakan sebagai berikut [30]:

1. Probabilitas Emisi (*Emission Probabilities*)

Untuk setiap titik GPS z_i dan setiap kandidat segmen jalan r_i , probabilitas emisi $p(z_i|r_i)$ dihitung. Probabilitas ini didasarkan pada jarak antara titik GPS dan titik terdekat di segmen jalan, dengan asumsi Gaussian noise:

$$p(z_t|r_i) = \frac{1}{\sqrt{2\pi}\sigma_z} e^{-\frac{1}{2}\left(\frac{\|z_t - x_{t,i}\|_{\text{great circle}}}{\sigma_z}\right)^2} \quad (2-3)$$

Di mana σ_z adalah standar deviasi dari GPS noise, $x_{t,i}$ adalah titik GPS terdekat pada segmen jalan r_i , sampai ke GPS point z_t .

2. Probabilitas Transisi (*Transition Probabilities*)

Probabilitas transisi $p(r_j|r_i)$ mewakili kemungkinan berpindah dari segmen jalan r_i ke segmen jalan r_j . Probabilitas ini dihitung berdasarkan jarak rute antara titik-titik di segmen-segmen ini dan jarak lingkaran besar antara titik-titik GPS yang sesuai:

$$p(d_t) = \frac{1}{\beta} e^{-\frac{d_t}{\beta}} \quad (2-4)$$

Di mana $d_t = \|z_t - z_{t+1}\|_{\text{great circle}} - \|x_{t,i} - x_{t+1,j}\|_{\text{route}}$ adalah parameter yang diestimasi dari data.

Algoritma viterbi kemudian digunakan untuk menemukan urutan segmen jalan (*hidden state*) yang paling mungkin mengingat urutan titik GPS (*observe state*). Algoritma ini bekerja dengan memaksimalkan nilai probabilitas emisi dan transisi sepanjang urutan observasi. Hasilnya adalah urutan segmen jalan yang paling sesuai dengan titik

GPS yang diamati.

2.2.7 PyTrack

PyTrack adalah sebuah *library* Python *open-source* yang dirancang untuk rekonstruksi lintasan kendaraan menggunakan teknik *map matching* [31]. *Library* ini dikembangkan untuk mendukung akademisi, peneliti, dan praktisi dalam mengintegrasikan koordinat GPS yang direkam dengan data dari OpenStreetMap (OSM), sebuah sistem informasi geografis *open-source*. PyTrack memungkinkan pengguna untuk memodelkan jaringan jalan, melakukan analisis topologi dan spasial, serta menjalankan proses *map matching* pada titik-titik lintasan GPS yang direkam [31].

Fitur utama dari PyTrack mencakup kemampuan untuk melakukan pemrosesan otomatis dan cerdas terhadap data OSM berdasarkan wilayah target dan area *buffer*. Selain itu, PyTrack memiliki modul rekonstruksi lintasan yang memungkinkan *snapping*, pembersihan data, interpolasi, dan *map matching* berdasarkan algoritma *Hidden Markov Model* (HMM) dan algoritma Viterbi.

Proses *map matching* dalam PyTrack dimulai dengan membangun graf jaringan jalan menggunakan data dari OSM. Graf ini kemudian diinterpolasi untuk meningkatkan akurasi hasil *map matching*. Setelah itu, titik-titik kandidat yang memiliki probabilitas tinggi untuk menjadi titik yang paling cocok dengan titik GPS aktual diidentifikasi. Titik-titik kandidat ini digunakan untuk membangun diagram trellis, yang merupakan graf asiklik terarah yang digunakan untuk memodelkan HMM. Algoritma Viterbi kemudian digunakan untuk menemukan urutan kandidat yang paling mungkin, menghasilkan rekonstruksi jalur jalan yang dilalui kendaraan.

Fungsi-fungsi utama yang digunakan dalam proses *map matching* dengan PyTrack meliputi:

- `graph_from_bbox`: Membuat graf jaringan jalan dari *bounding box* yang ditentukan.
- `get_candidates`: Mengidentifikasi titik-titik kandidat di sekitar titik GPS aktual.
- `create_trellis`: Membangun diagram trellis untuk memodelkan HMM.
- `viterbi_search`: Menjalankan algoritma Viterbi untuk menemukan urutan kandidat yang paling mungkin.

Visualisasi hasil map-matching dapat dilakukan menggunakan kelas *Map* dalam paket analitik PyTrack, yang memungkinkan pengguna untuk menampilkan graf jaringan jalan, titik-titik kandidat, dan jalur yang direkonstruksi pada peta interaktif.

2.2.8 MovingPandas

MovingPandas adalah sebuah *library* Python yang dirancang untuk analisis data pergerakan, khususnya data lintasan. *Library* ini dikembangkan untuk mengatasi keterbatasan model data pergerakan berbasis *simple features* yang umum digunakan dalam *Geographic Information System* (GIS), dengan memanfaatkan struktur data dari Pandas dan GeoPandas untuk menyediakan fungsionalitas yang lebih efisien dalam menangani data lintasan [32].

Fitur utama dari MovingPandas mencakup kemampuan untuk mengelola lintasan sebagai serangkaian geometri yang terurut berdasarkan waktu, yang disimpan dalam format GeoDataFrame. *Library* ini mendukung berbagai operasi geometris dan temporal, seperti menghitung panjang lintasan, durasi, kecepatan, dan arah. Selain itu, MovingPandas juga menyediakan fungsi untuk memotong lintasan dengan poligon dan menghitung interseksi dengan fitur spasial lainnya [32].

Dalam analisis lintasan, MovingPandas menawarkan berbagai fungsi yang umum digunakan. Misalnya, fungsi `add_speed` dan `add_direction` menambahkan kolom baru ke *trajectory* GeoDataFrame untuk menyimpan informasi kecepatan dan arah. Fungsi `get_position_at(timestamp, method='nearest')` memungkinkan akses ke posisi lokal pada waktu tertentu, sementara `get_length` dan `get_duration` digunakan untuk menghitung panjang dan durasi lintasan secara keseluruhan [32].

Penggunaan MovingPandas dalam analisis *trajectory* atau lintasan mencakup berbagai jenis analisis seperti segmentasi, analisis kesamaan, *clustering*, deteksi *outlier*, klasifikasi, deteksi *hotspot*, dan deteksi pola kelompok atau kawanan. Semua jenis analisis ini bergantung pada ukuran yang didefinisikan pada *trajectory*, yang dapat dihitung menggunakan fungsi-fungsi lintasan yang disediakan oleh *library* ini [32].

2.2.9 Koefisien Korelasi Pearson

Koefisien Korelasi Pearson adalah ukuran statistik yang digunakan untuk menentukan kekuatan dan arah hubungan linear antara dua variabel. Koefisien ini, yang sering dilambangkan dengan huruf "r", memiliki nilai yang berkisar antara -1 hingga 1. Nilai +1 menunjukkan hubungan linear positif yang sempurna, -1 menunjukkan hubungan linear negatif yang sempurna, dan 0 menunjukkan tidak adanya hubungan linear antara variabel-variabel tersebut [33]. Persamaan untuk menghitung koefisien Korelasi Pearson adalah:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} \quad (2-5)$$

Dengan x_i dan y_i adalah nilai dari variabel x dan y pada observasi ke-i, dan $\bar{x}$ dan


$\bar{y}$ adalah rata-rata dari variabel x dan y. Seberapa kuat hubungan antara dua variabel ditentukan oleh nilai absolut r, rentang interpretasi hubungan Korelasi Pearson dapat dilihat pada Tabel 2.3.

Tabel 2.3. Rentang interpretasi hubungan koefisien Korelasi Pearson [34]

Interpretasi kuat hubungan	Nilai Korelasi Pearson
<i>Negligible correlation</i>	0,00 – 0,10
<i>Weak correlation</i>	0,10 – 0,39
<i>Moderate correlation</i>	0,40 – 0,69
<i>Strong correlation</i>	0,70 – 0,89
<i>Very strong correlation</i>	0,90 – 1,00

2.2.10 Dynamic Time Warping (DTW)

Dynamic Time Warping (DTW) adalah teknik yang digunakan untuk mengukur kesamaan antara dua deret waktu yang mungkin bervariasi dalam kecepatan atau durasi [35]. DTW bekerja dengan menemukan penyelarasan optimal antara dua deret waktu dengan memperbolehkan peregangan atau penyusutan non-linear dari sumbu waktu. Gambaran visual dari DTW dapat dilihat pada Gambar ??.



Gambar 2.2. Dua *time-series* data yang dibandingkan [36]

Rumus dasar DTW melibatkan matriks jarak yang menghitung jarak antara setiap pasangan titik dalam dua deret waktu. Misalkan kita memiliki dua deret waktu $\mathbf{q} = (q_1, q_2, \dots, q_n)$ dan $\mathbf{c} = (c_1, c_2, \dots, c_m)$, matriks jarak $\mathbf{D}$ dihitung dengan $\mathbf{D}(i, j) = (q_i - c_j)^2$. Kemudian dicari jalur *warping* $\mathbf{w} = (w_1, w_2, \dots, w_k)$ yang meminimalkan total jarak antara dua deret waktu [37]. Cara kerja DTW mencari jalur *warping* melibatkan pengisian matriks kumulatif jarak minimal $\mathbf{D}'$, dengan setiap elemen $\mathbf{D}'(i, j)$ adalah jarak minimal dari titik awal hingga titik (i, j) . Persamaan rekursif untuk mengisi matriks ini adalah sebagai berikut:


$$\mathbf{D}'(i, j) = d(i, j) + \min(\mathbf{D}'(i-1, j), \mathbf{D}'(i, j-1), \mathbf{D}'(i-1, j-1)) \quad (2-6)$$

Dengan $d(i, j)$ adalah jarak antara elemen ke- i dari deret waktu pertama dan elemen ke- j dari deret waktu kedua. Setelah matriks ini terisi, jalur *warping* optimal dapat

ditemukan dengan melacak kembali dari $\mathbf{D}'(n, m)$ ke $\mathbf{D}'(1, 1)$ melalui elemen-elemen terkecil dari matriks [36].

2.2.11 Haversine Formula

Haversine adalah metode matematika yang digunakan untuk menghitung jarak antara dua titik di permukaan bumi, dengan memperhitungkan bahwa permukaan bumi tidak datar, melainkan melengkung seperti bola [38]. Umumnya, haversine digunakan pada data geografis karena dapat memberikan jarak *great circle* antara dua titik di permukaan bumi tanpa memandang ketinggian bukit dan kedalaman lembah di permukaan bumi [38].



Gambar 2.3. Ilustrasi jarak *great circle* antara dua titik (A dan B) pada bidang bola

Perhitungan jarak dengan formula haversine menggunakan perbedaan garis lintang dan garis bujur antara dua titik, yang dinyatakan dalam radian. Persamaan formula haversine antara dua titik A dan B dengan koordinat (ϕ_1, λ_1) dan (ϕ_2, λ_2) adalah sebagai berikut [38]:

$$d = 2r \arcsin \left(\sqrt{\sin^2 \left(\frac{\phi_2 - \phi_1}{2} \right) + \cos(\phi_1) \cos(\phi_2) \sin^2 \left(\frac{\lambda_2 - \lambda_1}{2} \right)} \right) \quad (2-7)$$

Keterangan:

- ϕ_1 = garis lintang (*latitude*) titik 1
- ϕ_2 = garis lintang (*latitude*) titik 2
- λ_1 = garis bujur (*longitude*) titik 1
- λ_2 = garis bujur (*longitude*) titik 2
- r = radius bumi ($\pm 6,371$ km)

BAB III

METODE PENELITIAN

3.1 Alat dan Bahan Tugas Akhir

3.1.1 Alat Tugas Akhir

Alat-alat yang digunakan pada tugas akhir ini berupa perangkat keras maupun perangkat lunak sebagai sarana pendukung antara lain:

1. Komputer *High Performance Computer* (HPC) dengan sistem operasi Linux versi 4.15.0-142-generic, 40-Core CPU, memori 251,86GB, dan disk size 52,65TB. Komputer ini merupakan komputer utama yang berfungsi untuk menyimpan data dan menjalankan kode, serta dapat diakses secara *remote*.
2. Jupyter Notebook yang berfungsi untuk menulis, menjalankan, memproses kode, dan menganalisis data menggunakan bahasa pemrograman Python. Jupyter Notebook terpasang pada komputer HPC sehingga hanya dapat diakses menggunakan jaringan internet UGM.
3. Laptop yang digunakan penulis untuk mengakses Jupyter Notebook menggunakan Lenovo IdeaPad 3 14ARE05 dengan spesifikasi AMD Ryzen 3 4300U, RAM 8GB, dan SSD 512GB.
4. *Browser* yang digunakan untuk mengakses Jupyter Notebook adalah Microsoft Edge versi 125.0.2535.79.
5. Bahasa pemrograman Python versi 3.8. dengan beberapa *library* yang digunakan antara lain:
 - Pandas versi 1.4.4, *library* yang digunakan untuk memproses data dalam bentuk DataFrame.
 - Numpy versi 1.23.5, *library* yang digunakan untuk operasi Python berbasis matematika seperti matriks dan vektor.
 - Geopandas versi 0.10.2, *library* yang digunakan untuk analisis data geospasial seperti data ruas jalan.
 - Folium versi 0.13.0, *library* yang digunakan untuk membuat peta interaktif guna melihat pemetaan data pada jalan.
 - Shapely versi 1.8.5, *library* yang digunakan untuk operasi geometri seperti *buffering* dan *overlay* guna memproses data GPS.
 - PyTrack versi 2.0.8, *library* yang digunakan untuk melakukan proses *path reconstruction* dan *map matching*.

- MovingPandas 0.17.2, *library* yang digunakan untuk melakukan analisis data GPS seperti *trajectory segmentation* dan *stay point detection*.
- Scipy versi 1.12.0, *library* yang digunakan untuk melakukan *map matching* dengan KD-Tree.
- NetworkX versi 2.8.8, *library* yang digunakan untuk membangun *graph* jaringan jalan yang digunakan pada *library* PyTrack.
- FastDTW versi 0.3.4, *library* yang digunakan untuk melakukan perbandingan data dengan *ground truth* menggunakan metode *Dynamic Time Warping* (DTW).

3.1.2 Bahan Tugas Akhir

Bahan tugas akhir ini terdiri dari beberapa dataset, diantaranya:

1. Dataset MPD aktif yang diperoleh dari salah satu perusahaan telekomunikasi terbesar di Indonesia. Dataset yang penulis gunakan pada rentang bulan Januari hingga Februari 2022. Rentang waktu tersebut dipilih karena data statistik arus lalu lintas untuk *ground truth* yang diperoleh dari Dinas Perhubungan DIY hanya tersedia untuk tahun 2022. Selain itu, data kedua bulan tersebut memiliki jumlah yang paling banyak dibandingkan bulan lain. Ukuran dataset MPD aktif pada bulan Januari hingga Februari 2022 adalah sebesar 4,4GB. Sampel dari dataset MPD aktif dapat dilihat pada Gambar 3.1 serta penjelasan setiap fiturnya pada Tabel 3.1.

	maid	latitude	longitude	timestamp
0	0000db5b-e162-4730-a6c5-11f65b3872b7	-7.800905	110.366638	2021-12-21 14:01:13
1	0000db5b-e162-4730-a6c5-11f65b3872b7	-7.800905	110.366640	2021-12-21 21:07:15
2	0000db5b-e162-4730-a6c5-11f65b3872b7	-7.800845	110.366638	2021-12-23 11:27:57
3	0000db5b-e162-4730-a6c5-11f65b3872b7	-7.800845	110.366640	2021-12-23 11:31:27
4	00012afc-6daf-461f-96a8-181e5af69db9	-7.800291	110.364998	2021-12-01 17:54:11

Gambar 3.1. Sampel data MPD aktif

Tabel 3.1. Fitur dataset MPD aktif

Fitur	Deskripsi
<i>maid</i>	ID unik yang digunakan untuk merepresentasikan setiap pengguna perangkat seluler. Fitur ini telah terenkripsi sehingga terjaga keamanannya
<i>latitude</i>	Koordinat garis lintang lokasi perangkat pengguna saat pengambilan titik data

<i>longitude</i>	Koordinat garis bujur lokasi perangkat pengguna saat pengambilan titik data
<i>timestamp</i>	Waktu ketika sebuah titik data diambil. Fitur ini disimpan menggunakan format UNIX

2. *Shapefile* ruas jaringan di sekitar Jalan Malioboro yang diperoleh dari OpenStreetMap (OSM). *Shapefile* ini berisi data geometri ruas jalan yang terdiri dari 896 ruas jalan. Sampel dari data ini dapat dilihat pada Gambar 3.2 serta penjelasan setiap fiturnya pada Tabel 3.2.

	name	geometry
0	Jalan Panembahan Senopati	LINESTRING (110.36943 -7.80153, 110.36945 -7.8...
1	Jalan Tentara Rakyat Mataram	LINESTRING (110.35918 -7.78753, 110.35932 -7.7...
2	Jalan Sam Ratulangi	LINESTRING (110.37631 -7.78300, 110.37633 -7.7...
3	Jalan Candrakirana	LINESTRING (110.37685 -7.78098, 110.37680 -7.7...
4	Jalan Jenderal Sudirman	LINESTRING (110.37462 -7.78299, 110.37402 -7.7...

Gambar 3.2. Sampel *shapefile* data ruas jalan

Tabel 3.2. Fitur dataset *shapefile* ruas jalan

Fitur	Deskripsi
<i>nama</i>	Nama ruas jalan
<i>geometry</i>	Kumpulan titik koordinat yang membentuk garis (<i>linestring</i>) yang merepresentasikan ruas jalan

3. Data riwayat kecepatan lalu lintas di Jalan Malioboro dari Google Maps yang diperoleh dari sebuah *Application Programming Interface* (API) terbuka bernama OutscraperAPI. Data ini berisi riwayat kecepatan rata-rata di ruas Jalan Malioboro dalam satuan jam. Data ini digunakan sebagai data *ground truth* untuk mengevaluasi akurasi hasil analisis kecepatan lalu lintas. Sampel dari data ini dapat dilihat pada Gambar 3.3 serta penjelasan setiap fiturnya pada Tabel 3.3.

	datetime_utc	distance(meters)	duration(minutes)
0	2022-02-01 00:00:00	1274	4
1	2022-02-01 01:00:00	1274	4
2	2022-02-01 02:00:00	1274	3
3	2022-02-01 03:00:00	1274	3
4	2022-02-01 04:00:00	1274	3

Gambar 3.3. Sampel data riwayat kecepatan lalu lintas Google Maps

Tabel 3.3. Fitur dataset riwayat kecepatan lalu lintas Google Maps

Fitur	Deskripsi
<i>datetime_utc</i>	Periode waktu pengambilan kecepatan rata-rata
<i>distance(meters)</i>	Jarak yang ditempuh antar titik, yaitu jarak ruas Jalan Malioboro sepanjang 1274 meter
<i>duration(minutes)</i>	Rata-rata durasi perjalanan yang ditempuh dalam satuan menit

4. Data survei arus lalu lintas di Jalan Malioboro dari Dinas Perhubungan DIY 2022 pada Jalan Malioboro. Data ini berisi arus lalu lintas dalam satuan mobil penumpang per jam (smp/jam) yang diukur pada beberapa periode waktu. Data ini digunakan sebagai data *ground truth* untuk mengevaluasi akurasi hasil analisis arus lalu lintas. Detail dari data ini dapat dilihat pada Gambar 3.4 serta penjelasan setiap fiturnya pada Tabel 3.4.

	Waktu	Periode	Smp/jam
0	06:00:00	Pagi	288
1	07:00:00	Pagi	359
2	08:00:00	Pagi	540
3	11:00:00	Siang	927
4	12:00:00	Siang	930
5	15:00:00	Sore	887
6	16:00:00	Sore	972
7	17:00:00	Sore	873

Gambar 3.4. Sampel data survei arus lalu lintas Dinas Perhubungan DIY

Tabel 3.4. Fitur dataset survei arus lalu lintas Dinas Perhubungan DIY

Fitur	Deskripsi
<i>Waktu</i>	Waktu pengambilan survei arus lalu lintas
<i>Periode</i>	Kategori waktu survei arus lalu lintas
<i>Smp/jam</i>	Jumlah satuan mobil penumpang per jam (smp/jam)

3.2 Metode yang Digunakan

Penelitian ini menggunakan metode analisis data deskriptif untuk mengidentifikasi pola kecepatan dan arus lalu lintas, serta analisis korelasi untuk mengevaluasi akurasi hasil analisis MPD aktif terhadap data *ground truth*. Analisis data dilakukan melalui beberapa tahapan yang dimulai dari *preprocessing data*, eliminasi titik *stay locations*, rekonstruksi rute perjalanan menggunakan metode *path reconstruction* dan *map matching*, interpolasi waktu, hingga visualisasi hasil analisis. Proses *preprocessing* melibatkan normalisasi data, penghapusan *noise*, *missing values*, serta *outliers* guna memastikan keakuratan data. Selanjutnya, dilakukan eliminasi titik *stay locations* untuk memperoleh data yang lebih akurat mengenai pergerakan seseorang. Metode *path reconstruction* dan *map matching* digunakan untuk memperkirakan rute yang ditempuh, sementara interpolasi waktu dilakukan untuk mendapatkan waktu di setiap titik rute hasil *path reconstruction*. Dengan menggunakan hasil rekonstruksi rute perjalanan dan waktu yang diperoleh, kecepatan dan arus lalu lintas pada Jalan Malioboro kemudian dihitung. Hasil analisis kemudian divisualisasikan dalam bentuk diagram menggunakan *library* Matplotlib.

Untuk melihat akurasi hasil analisis, dilakukan perbandingan dengan data *ground truth*. Data *ground truth* ini diperoleh dari dua sumber, yaitu data riwayat kecepatan dari Google Maps dan survei arus lalu lintas yang dilakukan oleh Dinas Perhubungan DIY pada tahun 2022 di Jalan Malioboro. Perbandingan dilakukan dengan menggunakan metode *Dynamic Time Warping* (DTW) serta koefisien Korelasi Pearson. DTW digunakan untuk mengukur seberapa baik kesesuaian antara dua data deret waktu, sedangkan koefisien korelasi digunakan untuk mengukur seberapa kuat hubungan linear antara hasil analisis dengan data *ground truth*. Semakin kecil jarak DTW menunjukkan tingkat kesesuaian yang baik antara dua data, sedangkan semakin besar jarak DTW menunjukkan tingkat kesesuaian yang buruk. Sementara itu, koefisien Korelasi Pearson yang tinggi menunjukkan tingkat kesesuaian yang baik antara hasil analisis dengan data *ground truth*, sedangkan koefisien korelasi yang rendah menandakan adanya kesesuaian yang buruk antara keduanya. Perbandingan ini bertujuan untuk menguji keakuratan dan keandalan hasil analisis yang telah dilakukan serta untuk mengidentifikasi area-area dimana analisis dapat ditingkatkan atau disempurnakan lebih lanjut.

Pendekatan penelitian ini bersifat iteratif, dimulai dengan pemilihan data acak untuk menginisiasi dan menguji proses penelitian. Iterasi pertama menghasilkan kode program kasar untuk pengolahan data dari awal hingga akhir, termasuk analisis dan visualisasi pola kecepatan dan arus. Tahap ini memberikan gambaran awal tentang tantangan yang dihadapi dan memungkinkan evaluasi kualitas data serta identifikasi proses yang dapat diperbaiki. Iterasi berikutnya bertujuan menyempurnakan alur proses pengolahan data dan kode program, memastikan bahwa analisis yang dihasilkan lebih baik dan akurat. Data yang digunakan diperluas pada iterasi ini untuk menguji kemampuan program pada dataset yang lebih besar dan kompleks. Iterasi-iterasi berikutnya fokus pada finalisasi proses pengolahan data dan analisis, serta evaluasi hasil dengan data *ground truth*.


Penelitian ini dilakukan dengan menggunakan HPC milik UGM sebagai komputer utama yang berfungsi untuk menyimpan data dan menjalankan kode. HPC digunakan karena pemrosesan data MPD aktif ini membutuhkan kemampuan komputasi yang tinggi. Kode program ditulis menggunakan bahasa pemrograman Python dengan bantuan *library* pendukung dan dijalankan menggunakan Jupyter Notebook. HPC ini hanya dapat diakses melalui jaringan internet UGM atau secara *remote* dengan akses *Virtual Private Network* (VPN) khusus.

3.3 Alur Tugas Akhir

Alur metode yang dilakukan pada penelitian ini digambarkan pada Gambar 3.5. Pada diagram alir tersebut terdapat beberapa proses yang dilakukan untuk menyelesaikan penelitian ini. Penjelasan masing-masing proses diuraikan sebagai berikut.

3.3.1 Mengumpulkan Data


Data yang digunakan terdiri dari 4 dataset, yaitu dataset MPD aktif, *shapefile* geometri ruas jalan, data riwayat kecepatan Google Maps, dan data survei arus lalu lintas Dinas Perhubungan DIY 2022. Data MPD aktif diperoleh dari kerja sama dengan perusahaan telekomunikasi di Indonesia. Data geometri ruas jalan diperoleh dari situs OpenStreetMap (OSM). Data riwayat kecepatan Google Maps diperoleh dari sebuah sumber terbuka, yaitu OutscraperAPI. Data survei arus lalu lintas diperoleh dari permohonan data kepada Dinas Perhubungan DIY. Dataset disimpan dalam format *Comma-Separated Values* (CSV), sementara itu *shapefile* geometri ruas jalan disimpan dalam format *.shp*. Keseluruhan dataset kemudian diunggah pada Jupyter Notebook dalam bentuk *DataFrame* menggunakan *library* Pandas untuk memudahkan proses analisis.



Gambar 3.5. Alur penelitian

3.3.2 Preprocessing Data


Tahap *preprocessing data* dilakukan untuk mempersiapkan data sebelum melalui proses selanjutnya. Seperti yang ditampilkan pada *flowchart* Gambar 3.6, data pertama-tama diubah dengan mengganti fitur *timestamp* yang masih berbentuk UNIX menjadi format *datetime* dengan format Waktu Indonesia Barat (WIB) atau GMT+7 sesuai dengan waktu daerah target lokasi, yaitu DIY. Kemudian untuk meringankan beban komputasi, titik point yang berada di luar radius $\pm 1,5$ km dari kawasan Malioboro akan dihapuskan. Radius 1,5 km dipilih karena dianggap cukup untuk mencakup pergerakan yang relevan di sekitar kawasan Jalan Malioboro tanpa memasukkan data yang tidak berhubungan langsung. Selanjutnya, data duplikat dihapus berdasarkan kesamaan fitur *maid* dan waktu untuk memastikan bahwa setiap entri unik dan menghindari bias dalam analisis [1]. Terakhir, data diurutkan berdasarkan fitur *maid* dan *timestamp* untuk menjaga urutan kronologis dan memudahkan proses analisis berikutnya.



Gambar 3.6. Flowchart metode *preprocessing data*

3.3.3 Mengeliminasi *Stay Locations*

Tahap selanjutnya adalah mengeliminasi titik *stay locations* dari data. *Stay locations* adalah titik geometri yang menunjukkan lokasi perangkat pengguna tidak bergerak atau berhenti dalam jangka waktu dan radius tertentu [39]. *Stay locations* dapat mengindikasikan lokasi seperti rumah, kantor, supermarket atau tempat-tempat lain dimana pengguna menghabiskan waktu yang cukup lama. Titik-titik tersebut tidak digunakan dalam penelitian karena tidak memberikan informasi yang relevan mengenai pergerakan di jalan. Proses eliminasi memanfaatkan bantuan *library* MovingPandas, yaitu `StopSplitter()`. Fungsi tersebut dapat mengidentifikasi titik-titik *stay locations* berdasarkan jarak dan waktu minimum yang ditentukan. Dalam penelitian ini digunakan jarak minimum 200 meter dalam waktu 30 menit sebagai batas eliminasi titik *stay locations* [40]. Batas tersebut berarti bahwa ketika seseorang menghabiskan waktu lebih dari 30 menit dalam radius 200 meter, titik tersebut dideteksi sebagai *stay locations* dan akan dihapuskan dari data.




Gambar 3.7. Flowchart metode eliminasi *stay locations*

Terlihat pada Gambar 3.7, proses ini melibatkan data GPS yang telah dilakukan proses *preprocessing* sebelumnya. Pertama, dibuat DataFrame baru yang berisi rentang waktu untuk setiap maid unik yang terdeteksi sebagai *stay locations* berdasarkan jarak dan waktu minimum yang ditentukan. Dari rentang tersebut kemudian dilakukan iterasi pada setiap baris data untuk mengecek apakah titik tersebut berada di rentang waktu *stay locations*. Apabila titik tersebut masuk ke dalam rentang durasi *stay locations*, maka titik tersebut akan dihapuskan.

3.3.4 Mengeliminasi Titik Jarak >20 meter dari Ruas Jalan

Tahap berikutnya adalah mengeliminasi titik yang berjarak lebih dari 20 meter dari ruas jalan. Tahap ini dilakukan mengingat target analisis adalah data pergerakan di jalan sehingga data yang tidak berada di jalan harus dihapuskan. Nilai 20 meter di pilih mengingat perekaman titik GPS yang tidak selalu akurat dan dapat bervariasi. Umumnya rentang error perekaman GPS sekitar 10-20 meter [41]. Proses ini dilakukan dengan bantuan *library* Shapely yang memiliki fungsi `buffer()` untuk membuat poligon seluas radius 20 meter dari jaringan jalan. Setelah itu dilakukan iterasi pada setiap titik


data GPS, apabila titik tersebut terdeteksi berada di luar poligon maka titik tersebut akan dihapuskan dari data. Garis besar alur proses ini dapat dilihat pada Gambar 3.8.



Gambar 3.8. *Flowchart* metode eliminasi titik jarak >20 meter dari ruas jalan

3.3.5 Map Matching dengan Algoritma KDTree

Tahap ini merupakan tahap penting dalam proses analisis data GPS. *Map matching* adalah proses yang digunakan untuk memetakan titik GPS ke ruas jalan terdekat [26]. Proses ini dilakukan dengan bantuan *library* Scipy dengan menerapkan algoritma KDTree. Algoritma KDTree digunakan karena efisien dalam memetakan titik GPS pada ruas jalan terdekat tanpa perlu melakukan pencarian secara linear [9]. Titik-titik GPS yang tadinya berada di luar ruas jalan karena pengambilan yang tidak akurat dapat dipetakan kembali ke ruas jalan terdekat.



Gambar 3.9. *Flowchart* metode *map matching* dengan algoritma KDTree

Sebagaimana divisualisasikan pada Gambar 3.9, masukan untuk proses ini terdiri dari *shapefile* geometri jaringan jalan dan DataFrame versi 3 dari proses sebelumnya. Langkah pertama dalam proses ini adalah membangun KDTree menggunakan data geometri dari jaringan jalan. Dalam KDTree ini, setiap *node* merepresentasikan titik-titik pada jaringan jalan. Setelah KDTree berhasil dibangun, langkah berikutnya adalah mencari titik jaringan jalan terdekat untuk setiap titik GPS. Proses ini dilakukan dengan iterasi melalui koordinat setiap titik GPS dan menggunakan KDTree untuk menemukan jarak terdekat dari titik-titik ini ke jaringan jalan. Titik-titik GPS tersebut kemudian dipetakan ke koordinat jalan terdekat berdasarkan indeks yang ditemukan oleh KDTree. Proses ini

menghasilkan data titik GPS yang telah disesuaikan sehingga titik-titik lokasinya berada pada jaringan jalan yang paling mendekati lokasi sebenarnya.

3.3.6 *Immobility Filter*


Tahap selanjutnya adalah proses *immobility filter*. *Immobility filter* adalah proses yang digunakan untuk mengeliminasi titik-titik yang berada pada koordinat yang sama persis untuk beberapa periode waktu [9]. Proses ini dibutuhkan karena setelah proses *map matching*, beberapa titik GPS mungkin akan berada di lokasi yang sama, baik karena perangkat pengguna benar-benar berhenti atau karena terdapat kesalahan dalam pengambilan data yang mungkin menyebabkan beberapa titik GPS saling bertumpuk pada lokasi yang sama setelah proses *map matching*. Adanya proses ini juga akan mengompresi data yang tidak memberikan makna yang signifikan sehingga meringankan beban komputasi. Oleh karena itu, *immobility filter* berperan penting dalam memastikan data yang dianalisis lebih bersih dan akurat dalam merepresentasikan pergerakan sebenarnya.

Seperti divisualisasikan pada Gambar 3.10, filter dimulai dengan melakukan iterasi dari setiap baris data GPS. Apabila variabel *prev_row* (titik GPS sebelumnya) kosong maka dilakukan inisiasi variabel *prev_row* dengan baris data pertama. Selanjutnya, dilakukan pengecekan pada baris data berikutnya, jika baris data tersebut sama dengan *prev_row* maka baris data tersebut akan dihapus, karena baris data tersebut dianggap sebagai titik yang tidak bergerak (*immobile point*) dan tidak memberikan informasi tambahan. Namun, jika baris data tersebut berbeda dengan *prev_row* maka baris data tersebut akan dipertahankan. Kemudian variabel *prev_row* akan diperbarui dengan baris data yang baru untuk melakukan iterasi selanjutnya. Proses ini terus berlanjut hingga semua baris data telah dilakukan pengecekan. Hasil akhirnya adalah kumpulan titik GPS yang hanya terdiri dari titik-titik yang memiliki perubahan posisi, sehingga merepresentasikan pergerakan sebenarnya.


3.3.7 *Menyesuaikan Titik dengan Arah Jalur Jalan*

Tahap berikutnya adalah tahap menyesuaikan titik dengan jalur jalan. Proses ini bertujuan untuk memastikan bahwa titik GPS yang telah dipetakan ke ruas jalan berada di arah jalur jalan yang benar. Proses ini penting untuk meminimalisir kesalahan saat implementasi *path reconstruction* karena titik mungkin terdeteksi berada di arah jalur jalan yang salah. Proses ini harus dilakukan karena proses *map matching* sebelumnya tidak memperhitungkan arah pergerakan pengguna, sehingga titik GPS yang dipetakan ke ruas jalan mungkin tidak berada di arah jalur jalan yang benar. Sebagaimana divisualisasikan pada Gambar 3.11, proses ini melibatkan data GPS dari proses sebelumnya dan data *shapefile* geometri jaringan jalan.

Pertama, setiap baris pada data GPS dihitung nilai *bearing*-nya, nilai *bearing* lalu



Gambar 3.10. Flowchart metode *immobility filter*



Gambar 3.11. *Flowchart* metode menyesuaikan titik dengan arah jalur jalan

ditambahkan menjadi fitur DataFrame. Nilai *bearing* menunjukkan besar sudut arah pergerakan titik GPS terhadap titik GPS sebelumnya, dengan satuan derajat yang berkisar antara $0^\circ - 360^\circ$. Selanjutnya, dibuat *graph* berarah (*MultiDiGraph*) dari data jaringan jalan untuk merepresentasikan jaringan jalan. Jika pada proses *map matching* sebelumnya hanya digunakan *graph* satu arah (*Graph*), pada tahap ini digunakan *graph* berarah karena *graph* berarah dapat merepresentasikan arah jalur yang berbeda dalam satu ruas jalan.


Proses selanjutnya dilakukan pada DataFrame GPS, dilakukan iterasi melalui setiap baris data GPS dan setiap *edge* dalam *graph* jaringan jalan. Dalam iterasi ini, dicari *edge* yang memiliki jarak paling dekat dari titik GPS. Setelah *edge* terdekat ditemukan, *edge* tersebut akan disimpan. Untuk memastikan bahwa *edge* tersebut benar-benar sesuai dengan titik GPS, dilakukan perhitungan sudut antara *bearing* titik GPS dengan *bearing* dari *edge*. Jika sudut tersebut berada dalam rentang $-90^\circ \leq x \leq 90^\circ$ maka titik GPS tersebut dianggap berada pada jalur jalan yang benar. Oleh karena itu, titik GPS akan diganti dengan titik terdekat pada *edge* sebagai titik baru. Namun, jika tidak ada *edge* yang sesuai ditemukan, akan digunakan titik GPS yang asli. Proses ini bertujuan untuk menghasilkan data GPS yang telah disesuaikan dengan arah jalur jalan.

3.3.8 Split Trajectory berdasarkan Waktu Observasi

Tahap selanjutnya adalah membagi data GPS menjadi *trajectory* berdasarkan waktu observasi. *Trajectory* adalah kumpulan titik GPS yang merepresentasikan pergerakan seseorang dalam jangka waktu tertentu [42]. Proses ini dilakukan dengan bantuan *library* MovingPandas yang memiliki fungsi `ObservationGapSplitter()` untuk membagi data GPS menjadi beberapa *trajectory* berdasarkan waktu observasi. Fungsi ini memisahkan *trajectory* apabila antar titik nya memiliki selisih waktu lebih dari batas yang ditentukan. Dalam penelitian ini, batas waktu observasi yang ditentukan adalah 10 menit. Batas ini dipilih berdasarkan penelitian yang dilakukan oleh Zheng *et al.* [43] yang menyatakan bahwa efek dari gap waktu observasi yang lebih lama dari 10 menit dapat menurunkan akurasi hasil analisis secara signifikan. Oleh karena itu, batas gap waktu observasi 10 menit dipilih untuk memastikan bahwa data yang dianalisis lebih akurat dan relevan.

Proses ini divisualisasikan pada Gambar 3.12. Proses ini dimulai dengan melakukan iterasi pada setiap baris data GPS. Pemisahan *trajectory* ini dikelompokkan untuk setiap maid unik, sehingga satu maid unik dapat menjadi beberapa *trajectory* yang berbeda. Pada saat iterasi berlangsung, dilakukan pengecekan pada gap waktu observasi antar titik. Jika gap melebihi batas waktu 10 menit, titik tersebut akan memisahkan diri dan menjadi titik awal *trajectory* yang baru. Proses ini terus berlanjut hingga semua baris data selesai diperiksa. Hasil dari proses ini adalah data GPS yang terbagi menjadi kumpulan


trajectory dengan waktu observasi yang lebih berdekatan.



Gambar 3.12. Flowchart metode *split trajectory*

3.3.9 Path Reconstruction

Untuk dapat melakukan perhitungan kecepatan dan arus lalu lintas, dibutuhkan informasi rute yang ditempuh oleh perangkat pengguna. Informasi ini diperoleh melalui proses *path reconstruction* yang bertujuan untuk merekonstruksi rute perjalanan berdasarkan titik-titik GPS yang ada. Data GPS yang tersedia saat ini adalah kumpulan titik GPS yang memiliki banyak kekosongan, proses ini bertujuan untuk mengisi kekosongan tersebut dengan merekonstruksi rute perjalanan yang ditempuh oleh pengguna. Proses ini dilakukan dengan bantuan *library* PyTrack dengan algoritma *Hidden Markov Model* (HMM) dan Viterbi.



Gambar 3.13. Flowchart metode *path reconstruction*

Proses *path reconstruction* terdiri dari beberapa tahap, seperti yang terlihat pada *flowchart* di Gambar 3.13. Proses ini dimulai dengan membangun *graph* menggunakan *library* NetworkX untuk merepresentasikan jaringan jalan. Selanjutnya, dilakukan iterasi pada setiap *trajectory* hasil dari proses sebelumnya. Untuk setiap satuan *trajectory*, dilakukan iterasi pada setiap titik GPS untuk menemukan titik kandidat, yaitu titik pada jaringan jalan yang memiliki probabilitas emisi tinggi untuk menjadi titik yang paling cocok dengan titik GPS yang sebenarnya. Pada proses HMM, titik GPS merupakan variabel observasi, sedangkan titik kandidat atau titik jaringan jalan merupakan variabel tersembunyi. Probabilitas emisi dihitung berdasarkan jarak *great circle* dari titik GPS ke titik

kandidat terdekat. Titik-titik kandidat ini kemudian digunakan untuk membangun diagram trellis, yaitu *graph* asiklik terarah yang merepresentasikan HMM. Dalam diagram ini, setiap *node* merupakan titik kandidat, sedangkan setiap *edge* adalah nilai probabilitas transisi antar titik kandidat. Setelah itu, algoritma Viterbi diterapkan pada diagram trellis untuk menemukan urutan titik kandidat yang paling mungkin berdasarkan probabilitas transisi. Hasil dari algoritma Viterbi adalah urutan titik kandidat yang paling mewakili jalur pergerakan yang sebenarnya di jaringan jalan. Tahap ini menghasilkan titik-titik rute yang lebih konsisten dan kontinu untuk setiap *trajectory*, sehingga membuat jalur perjalanan pengguna menjadi lebih jelas dan terhubung dengan baik.

3.3.10 Interpolasi Waktu

Tahap selanjutnya adalah interpolasi waktu, yang bertujuan untuk melengkapi nilai waktu pada titik-titik GPS baru yang telah direkonstruksi. Titik-titik ini awalnya tidak memiliki nilai waktu karena proses *path reconstruction* hanya menghasilkan titik-titik baru tanpa informasi waktu. Tahap ini penting untuk memastikan bahwa titik yang dihasilkan memiliki waktu yang lengkap dan konsisten. Proses interpolasi dilakukan dengan metode linear, dimana nilai waktu yang kosong diisi dengan nilai rata-rata waktu dari titik sebelum dan sesudahnya.

Seperti yang ditunjukkan pada Gambar 3.14, proses ini dimulai dengan melakukan iterasi pada setiap titik GPS hasil rekonstruksi. Dari setiap titik GPS, program memeriksa apakah nilai waktu pada titik tersebut kosong. Jika iya, program akan menyimpan index titik tersebut kemudian melakukan iterasi lagi sampai menemukan titik berikutnya yang memiliki nilai waktu. Selanjutnya, nilai waktu yang kosong pada titik-titik tersebut akan diisi dengan nilai interpolasi dari dua titik GPS yang mengapit. Perhitungan interpolasi linear dilakukan dengan Persamaan 3-1.


$$\Delta t = t_2 - t_1 \quad (3-1)$$

Dengan t_1 dan t_2 sebagai waktu dari dua titik GPS yang mengapit, dan Δt sebagai selisih waktunya. Kemudian untuk mengestimasi waktu di setiap titik-titik yang hilang akan dicari nilai δt . Nilai tersebut dihitung dengan membagi selisih waktu Δt dengan $n + 1$, dimana n adalah jumlah titik baru yang tidak memiliki nilai waktu (Persamaan 3-2).

$$\delta t = \frac{\Delta t}{n + 1} \quad (3-2)$$

$$t_i = t_i + (i \times \delta t) \quad (3-3)$$

Sehingga untuk setiap titik-titik baru, nilai waktu t_i bisa dihitung menggunakan Persamaan 3-3. Variabel i mewakili indeks titik baru yang dihasilkan dari proses *path reconstruction*. Dengan nilai $i = 1, 2, \dots, n$, i memainkan peran penting dalam menghasilkan estimasi nilai waktu berdasarkan urutan yang sesuai dari titik-titik tersebut. Proses ini akan berlanjut hingga semua baris data telah diperiksa. Hasilnya adalah data *trajectory* yang lengkap dengan nilai waktu pada setiap titik GPS. Metode interpolasi waktu ini memastikan bahwa titik baru akan memiliki nilai waktu yang konsisten untuk merepresentasikan pergerakan temporal seseorang sesuai dengan hasil rekonstruksi rute perjalanan.



Gambar 3.14. Flowchart metode interpolasi waktu

3.3.11 Perhitungan Kecepatan dan Arus Lalu Lintas

Proses perhitungan kecepatan dan arus dilakukan setelah proses *path reconstruction* dan interpolasi waktu selesai. Proses ini bertujuan untuk menghitung estimasi rata-rata kecepatan dan arus lalu lintas di Jalan Malioboro berdasarkan data GPS yang telah diolah sebelumnya. Sebagaimana ditampilkan pada *flowchart* pada Gambar 3.15, terdapat dua objektif pada tahap analisis ini, yaitu menghitung kecepatan dan arus lalu lintas pada Jalan Malioboro. Masukan pada tahap ini adalah DataFrame versi 9 yang mana berupa data satuan *trajectory* yang telah direkonstruksi dan memiliki waktu yang lengkap pada setiap titik GPS. Proses pertama yang dilakukan adalah mengambil titik-titik GPS yang berada di ruas Jalan Malioboro saja. Hal ini dilakukan dengan bantuan *shapefile* geometri ruas Jalan Malioboro yang dibentuk menjadi poligon. Titik-titik GPS yang berada di luar poligon tersebut akan dihapuskan. Hal ini bertujuan untuk memastikan bahwa data yang dianalisis hanya berupa data pergerakan di Jalan Malioboro saja.

Kecepatan rata-rata di Jalan Malioboro didapatkan dari rata-rata kecepatan kumpulan *trajectory* yang melewati ruas Jalan Malioboro. Kecepatan tiap *trajectory* atau vi dihitung berdasarkan perpindahan titik GPS (p_i, p_{i+n}) , dimana n adalah jumlah titik GPS hasil rekonstruksi perjalanan yang melewati Jalan Malioboro. Kemudian kecepatan vi didapatkan dari pembagian jarak perpindahan $Dist(p_i, p_{i+n})$ dengan waktu yang dibutuhkan untuk melakukan perpindahan $t_{i+n} - t_i$ (lihat Persamaan 3-4). Selanjutnya, untuk mencari


kecepatan rata-rata v_{avg} dapat dihitung dari jumlah seluruh kecepatan *trajectory* v_i dibagi dengan n , dengan n adalah jumlah *trajectory* (lihat Persamaan 3-5).

$$v_i = \frac{Dist(p_i, p_{i+n})}{(t_{i+n} - t_i)} \quad (3-4)$$

$$v_{avg} = \frac{\sum_i^n v_i}{n} \quad (3-5)$$

Dalam perhitungan kecepatan ini, diasumsikan bahwa perpindahan titik GPS yang dihitung hanyalah perpindahan dari arah utara ke selatan, sesuai dengan karakteristik Jalan Malioboro yang merupakan jalan satu arah. Oleh karenanya, penulis menggunakan *bearing* untuk menentukan jenis *trajectory* yang akan dihitung dan yang tidak. *Trajectory* yang memiliki nilai *bearing* di luar dari $180^\circ - 190^\circ$ (bergerak dari utara ke selatan) tidak akan dihitung. Hal ini dilakukan karena penelitian ini hanya fokus pada kondisi lalu lintas di jalan, sehingga pergerakan yang berada di luar jalan tidak diperhitungkan.

Sementara itu, arus lalu lintas dihitung berdasarkan jumlah *trajectory* yang berada di ruas Jalan Malioboro pada waktu tertentu. Setiap *trajectory* dianggap sebagai satu unit pergerakan yang berkontribusi pada arus di Jalan Malioboro karena masing-masing *trajectory* mewakili pergerakan seseorang yang melintasi jalan tersebut. Namun, perlu diketahui bahwa perhitungan arus lalu lintas dalam penelitian ini hanya bersifat sampel dan tidak merepresentasikan arus lalu lintas secara keseluruhan, mengingat data yang digunakan juga memiliki jumlah yang terbatas. Oleh karena itu, perhitungan arus lalu lintas pada penelitian ini lebih fokus pada perubahan arus yang terjadi pada waktu tertentu daripada arus keseluruhan lalu lintas. Hasil dari keseluruhan tahap analisis ini adalah data kecepatan dan arus lalu lintas di Jalan Malioboro yang siap dilakukan proses analisis lebih lanjut.



Gambar 3.15. *Flowchart* metode perhitungan kecepatan dan arus lalu lintas

3.3.12 Analisis Pola Lalu Lintas

Tahap selanjutnya adalah analisis pola lalu lintas, yang terdiri dari analisis kecepatan dan analisis arus lalu lintas di Jalan Malioboro. Tujuan dari tahap ini adalah untuk

mengidentifikasi pola lalu lintas di Jalan Malioboro berdasarkan MPD aktif yang telah melalui berbagai macam proses sebelumnya. Fokus analisis ini adalah pada perbandingan pola hari kerja dan akhir pekan, serta pola sepanjang hari. Fokus ini dipilih mengingat target analisis yaitu Jalan Malioboro merupakan salah satu kawasan wisata yang memiliki karakteristik lalu lintas yang berbeda berdasarkan periode waktu dan hari tertentu. Hasil analisis ini akan dijelaskan secara detail pada BAB IV Hasil dan Pembahasan.

3.3.13 Membandingkan Hasil Analisis dengan Data *Ground Truth*

Tahap terakhir adalah membandingkan hasil analisis dengan data *ground truth* yang diperoleh dari sumber lain. Tahap ini merupakan tahap yang dilakukan setelah hasil analisis ditemukan dan bertujuan untuk melihat sejauh mana analisis pola kecepatan dan arus menggunakan MPD aktif sesuai dengan kondisi sebenarnya di lapangan. Untuk membandingkan hasil analisis kecepatan lalu lintas, data akan dibandingkan dengan data riwayat kecepatan dari Google Maps. Sedangkan untuk membandingkan hasil analisis arus lalu lintas, data akan dibandingkan dengan data survei arus lalu lintas Dinas Perhubungan DIY 2022. Untuk mendapatkan perbandingan yang setara, rentang waktu yang digunakan sebagai pembanding disesuaikan dengan rentang waktu data hasil analisis.

Penggunaan riwayat kecepatan dari Google Maps sebagai data *ground truth* dalam analisis kecepatan lalu lintas didasarkan pada beberapa alasan yang kuat. Pertama, penelitian yang dilakukan oleh Alsobky *et al.* [44] menunjukkan bahwa API Google Maps dapat digunakan untuk mengestimasi kecepatan aliran bebas dengan tingkat akurasi yang tinggi, yang dibandingkan dengan data yang dikumpulkan menggunakan metode Moving Car atau GPS di Kairo, Mesir. Penelitian oleh Paramesti *et al.* [45] juga mendukung keandalan data Google Maps dengan menunjukkan bahwa tidak ada perbedaan signifikan antara kecepatan dan panjang antrian yang diukur melalui Google Maps dan survei lapangan di Yogyakarta. Selain itu, penelitian oleh Rodrigues *et al.* [46] menunjukkan bahwa data dari Google Maps dapat digunakan sebagai referensi untuk melakukan validasi model prediksi lalu lintas dan kecepatan kendaraan dengan andal. Dengan bukti-bukti tersebut, Google Maps dapat dijadikan sebagai data *ground truth* yang dapat diandalkan dalam validasi akurasi kecepatan lalu lintas.

Metode perbandingan yang digunakan adalah dengan menghitung jarak *Dynamic Time Warping* (DTW) dan nilai koefisien Korelasi Pearson antara data hasil analisis dengan data *ground truth*. Jarak DTW digunakan untuk mengukur seberapa dekat dua data deret waktu, sedangkan koefisien Korelasi Pearson digunakan untuk mengukur seberapa kuat hubungan linear antara dua variabel. Dengan metode ini, diharapkan dapat memberikan gambaran yang lebih jelas mengenai seberapa akurat hasil analisis yang dilakukan menggunakan MPD aktif.

3.4 Keterbatasan Penelitian

Pada penelitian ini, terdapat beberapa keterbatasan yang perlu diperhatikan. Keterbatasan tersebut diantaranya adalah:

1. Keterbatasan informasi pergerakan: Data yang digunakan hanya berupa data GPS yang merepresentasikan pergerakan seseorang. Data ini tidak menyertakan informasi lain seperti bagaimana pengguna melakukan mobilitas atau informasi lain yang dapat memberikan konteks lebih lanjut terhadap pergerakan yang terjadi.
2. Keterbatasan cakupan data: Jumlah dataset yang digunakan hanya terdiri dari ID pengguna yang berjumlah 10% dari total penduduk DIY, sehingga data ini mungkin tidak mencakup seluruh pergerakan di Jalan Malioboro. Keterbatasan ini dapat memengaruhi representasi dan generalisasi hasil analisis terhadap kondisi lalu lintas yang sebenarnya di area tersebut.
3. Keterbatasan dalam memisahkan pergerakan non-lalu lintas: Terdapat kemungkinan hasil analisis dapat tercampur antara pergerakan di jalan dan pergerakan di trotoar yang tidak berkontribusi pada arus lalu lintas. Meskipun telah diterapkan metode untuk mengambil data yang terkait dengan lalu lintas saja, termasuk mengeliminasi data dengan kecepatan di bawah 5 km/jam (kecepatan pejalan kaki), masih terdapat kemungkinan bahwa hasil analisis mencakup kedua jenis pergerakan tersebut. Hal ini disebabkan oleh variasi data GPS yang tidak selalu akurat. Keterbatasan ini dapat mempengaruhi akurasi analisis dalam mengidentifikasi pola kecepatan dan arus lalu lintas di Jalan Malioboro.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Rekonstruksi Rute Perjalanan Kendaraan

Subbab ini merupakan hasil dari rumusan masalah yang pertama, yaitu tentang merekonstruksi rute perjalanan pengguna berdasarkan data GPS. Pada tahap ini, penulis melakukan rekonstruksi rute perjalanan menggunakan metode *path reconstruction* dan interpolasi waktu. Rekonstruksi rute perjalanan dilakukan untuk mencari kecepatan dan arus dengan titik-titik GPS yang membentuk *trajectory* sebagai titik acuan perjalanan. Subbab ini terdiri dari 2 bagian, yaitu pembahasan tentang hasil *preprocessing data* MPD aktif sampai siap digunakan untuk proses rekonstruksi rute perjalanan, serta hasil rekonstruksi rute perjalanan menggunakan *path reconstruction* dan interpolasi waktu.


4.1.1 Data MPD Aktif Setelah Tahap *Preprocessing Data*

Pada tahap ini, penulis melakukan berbagai metode pada dataset sebelum dilakukan proses rekonstruksi rute perjalanan. Metode yang dilakukan terdiri dari *preprocessing* awal, mengeliminasi *stay locations*, mengeliminasi titik jarak >20 meter dari ruas jalan, *map matching* dengan algoritma KDTree, *immobility filter*, serta menyesuaikan titik dengan arah jalur jalan. Setelah proses ini dilakukan, hasilnya akan dipisahkan berdasarkan waktu observasi dengan *split trajectory* yang kemudian menjadi input implementasi rekonstruksi rute perjalanan dengan *path reconstruction* dan interpolasi waktu. Perubahan data seiring implementasi metode ditampilkan pada Tabel 4.1.

Proses awal yang dilakukan berupa *preprocessing dataset* MPD aktif dengan mengubah format data mentah menjadi data yang siap digunakan untuk tahap-tahap selanjutnya. Proses ini menghasilkan DataFrame bulan Januari dan Februari yang terdiri dari 2.195.131 titik data GPS yang berasal dari 121.543 ID pengguna unik, sebanyak 64,95% data berasal dari bulan Februari sedangkan 34,96% berasal dari bulan Januari. Distribusi maid unik setiap harinya terlihat pada Gambar 4.1, yang menunjukkan variasi jumlah pengguna unik yang berkontribusi pada dataset setiap harinya selama dua bulan.

Setelah tahap *preprocessing*, dilakukan proses eliminasi *stay locations*. Proses ini menghapus titik GPS yang terdeteksi berhenti dalam jangka waktu minimal 30 menit dalam radius 200 meter. Proses ini dilakukan untuk setiap maid unik yang ada pada dataset. Terdapat sekitar 1.853.008 atau sekitar 84,4% titik data GPS yang tereliminasi pada proses ini, mengindikasikan bahwa sebagian besar data diambil saat pengguna sedang melakukan kegiatan di suatu tempat. Hasil ini juga berarti bahwa MPD aktif yang dipakai sebagai bahan penelitian memiliki tingkat mobilitas yang rendah.

Proses selanjutnya adalah mengeliminasi titik dengan jarak >20 meter dari ruas









Gambar 4.1. Distribusi maid unik setiap harinya

jalan. Proses ini bertujuan untuk menghilangkan titik-titik yang tidak berada di ruas jalan karena tidak berkontribusi pada arus lalu lintas. Titik-titik tersebut kemungkinan besar berada di dalam bangunan atau berada di tempat yang tidak dapat dilalui kendaraan. Proses ini dilakukan dengan membuat poligon dengan *buffer* sejauh 20 meter dari ruas jalan dan menghapus data di luar poligon tersebut. Data yang tereliminasi dalam proses ini tidak terlalu signifikan, hanya sebanyak 1.379 atau 0,4% titik data GPS data yang terhapus. Hal ini kemungkinan terjadi karena data yang jauh dari ruas jalan sudah tereliminasi pada proses eliminasi *stay locations* sebelumnya.

Proses berikutnya adalah implementasi *map matching* dengan algoritma KDTree untuk memetakan titik-titik GPS pada ruas jalan terdekat. Tidak seperti proses sebelumnya yang mengubah jumlah data, proses ini tidak menghilangkan titik GPS, tetapi mengubah koordinat titik GPS agar masuk pada ruas jalan terdekat. Terlihat pada Tabel 4.1 Tahap 4, pada visualisasi sampel terlihat bahwa titik-titik GPS yang semula tersebar di sekitar ruas jalan, kini telah masuk dengan ruas jalan terdekat.

Setelah proses pemetaan, akan terdapat titik-titik yang bertumpuk pada lokasi yang sama sehingga dilakukan *immobility filter* untuk menghilangkan titik-titik tersebut. Terbukti sebanyak 110.918 titik data GPS tereliminasi pada proses ini, mengindikasikan bahwa sebanyak 48,3% titik data GPS hasil pemetaan saling bertumpuk pada lokasi yang sama. Titik-titik tersebut mungkin diambil saat pengguna sedang melakukan kegiatan di suatu tempat atau saat pengguna berhenti dalam waktu yang cukup lama, tetapi tidak terdeteksi oleh proses eliminasi *stay locations* sebelumnya. Hasil dari proses ini adalah data titik-titik GPS yang lebih bersih dan representatif.

Tabel 4.1. Hasil implementasi *preprocessing data*

Tahap	1	2	3	4	5	6
Metode	<i>Preprocessing Data</i>	Mengeliminasi <i>Stay Locations</i>	Mengeliminasi Titik Jarak >20 meter dari Ruas Jalan	<i>Map Matching</i> dengan Algoritma KDTree	<i>Immobility Filter</i>	Menyesuaikan Titik dengan Arah Jalur Jalan
Sample Visualisasi						
Jumlah Titik Data GPS	2.195.131	342.123	340.744	340.744	229.826	229.826
Persentase Data	100%	15,58%	15,52%	15,52%	10,46%	10,46%

Proses terakhir adalah menyesuaikan titik dengan arah jalur jalan. Proses ini akan mengubah posisi titik-titik GPS yang berada pada jaringan jalan dengan jalur dua arah. Titik-titik tersebut akan digeser supaya mendekati jalur jalan yang sesuai dengan arah pergerakan pengguna berdasarkan hasil perhitungan *bearing* atau arah pergerakan. Pada Tabel 4.1 Tahap 6, memang tidak terlalu terlihat perubahan visualisasi yang signifikan karena jaringan jalan yang digunakan sebagai sampel adalah jalan satu arah.

4.1.2 Rekonstruksi Rute Perjalanan menggunakan Metode *Path Reconstruction* dan Interpolasi Waktu

Hasil dari tahap *preprocessing* sebelumnya menjadi input untuk proses rekonstruksi rute perjalanan menggunakan metode *path reconstruction* dan interpolasi waktu. Sebelum proses ini diterapkan, titik-titik data GPS harus dipisahkan lagi berdasarkan waktu observasi. Hal ini bertujuan untuk meminimalisir terjadinya kesalahan rekonstruksi rute perjalanan yang disebabkan oleh frekuensi pengambilan data yang terlalu jauh. Oleh sebab itu, dilakukan proses *split trajectory* untuk memisahkan data GPS berdasarkan waktu observasi dengan jarak waktu antar titik maksimal 10 menit. Proses ini dilakukan untuk setiap maid unik yang ada pada dataset.

	maid	timestamp	adjusted_way_latitude	adjusted_way_longitude
0	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-09 10:50:30	-7.782755	110.359861
1	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-09 10:51:52	-7.782694	110.356784
2	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-14 13:13:18	-7.781798	110.373925
3	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-14 13:14:39	-7.782827	110.367562
4	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-14 13:17:24	-7.790907	110.366080
5	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-14 13:18:46	-7.793937	110.364967
6	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-14 13:20:08	-7.793513	110.361309
7	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-14 13:21:29	-7.793027	110.356609
8	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-15 08:39:33	-7.782841	110.358722
9	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-15 13:11:02	-7.780903	110.375180
10	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-17 08:52:25	-7.782702	110.357426
11	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-17 08:53:48	-7.784438	110.357644
12	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-17 08:55:09	-7.784661	110.357599
13	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-17 08:56:31	-7.784403	110.357503
14	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-20 11:27:13	-7.782856	110.360721
15	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-20 14:10:25	-7.780732	110.360871
16	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-20 14:11:47	-7.782077	110.360650
17	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-20 14:13:26	-7.782856	110.360721
18	0229383e-383e-e89b-8d02-6ee2915cb645	2022-02-20 14:14:47	-7.782702	110.357426

Gambar 4.2. Sampel data GPS sebelum dilakukan *split trajectory*

Sebagai gambaran, ditampilkan sampel dari sebuah maid unik yang berupa Data-Frame titik-titik GPS pada Gambar 4.2 saat belum dilakukan *split trajectory*. Pada data ini terdapat 18 titik data GPS yang terhubung satu sama lain dengan rentang waktu yang beragam. Apabila dilakukan rekonstruksi rute perjalanan pada data ini, hasil analisis akan menjadi kurang baik karena frekuensi waktu yang terlalu jauh. Selain itu, prosesnya akan memakan sumber daya komputasi yang besar. Dengan demikian, dilakukan proses

split trajectory dengan hasil seperti yang terlihat pada Gambar 4.3. Pada hasil ini, terbentuk 4 *trajectory* yang terpisah. Frekuensi titik GPS pada *trajectory* ini memiliki jarak waktu yang tidak lebih dari 10 menit. *Trajectory* yang terbentuk yaitu *trajectory* 0, 1, 4, dan 6. *Trajectory* 2, 3, dan 5 dieliminasi pada proses ini karena *trajectory* tersebut hanya terdiri dari 1 titik, sedangkan untuk membentuk sebuah *trajectory* atau perjalanan minimal dibutuhkan 2 titik. Karena *trajectory* tersebut tidak memenuhi syarat maka kemudian dihapuskan. Proses ini dilakukan untuk setiap maid unik sehingga proses ini menghasilkan kumpulan titik-titik GPS yang membentuk *trajectory*, dengan tiap *trajectory* merepresentasikan perjalanan seseorang dalam periode waktu tertentu. Dihasilkan sekitar 175.964 titik GPS yang terdiri dari 30.482 *trajectory* yang siap digunakan sebagai input untuk proses rekonstruksi rute perjalanan selanjutnya.

	maid_trajectory	adjusted_way_latitude	adjusted_way_longitude	timestamp
0	0229383e-383e-e89b-8d02-6ee2915cb645_0	-7.782755	110.359861	2022-02-09 10:50:30
1	0229383e-383e-e89b-8d02-6ee2915cb645_0	-7.782694	110.356784	2022-02-09 10:51:52
2	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.781798	110.373925	2022-02-14 13:13:18
3	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.782827	110.367562	2022-02-14 13:14:39
4	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.790907	110.366080	2022-02-14 13:17:24
5	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.793937	110.364967	2022-02-14 13:18:46
6	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.793513	110.361309	2022-02-14 13:20:08
7	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.793027	110.356609	2022-02-14 13:21:29
8	0229383e-383e-e89b-8d02-6ee2915cb645_4	-7.782702	110.357426	2022-02-17 08:52:25
9	0229383e-383e-e89b-8d02-6ee2915cb645_4	-7.784438	110.357644	2022-02-17 08:53:48
10	0229383e-383e-e89b-8d02-6ee2915cb645_4	-7.784661	110.357599	2022-02-17 08:55:09
11	0229383e-383e-e89b-8d02-6ee2915cb645_4	-7.784403	110.357503	2022-02-17 08:56:31
12	0229383e-383e-e89b-8d02-6ee2915cb645_6	-7.780732	110.360871	2022-02-20 14:10:25
13	0229383e-383e-e89b-8d02-6ee2915cb645_6	-7.782077	110.360650	2022-02-20 14:11:47
14	0229383e-383e-e89b-8d02-6ee2915cb645_6	-7.782856	110.360721	2022-02-20 14:13:26
15	0229383e-383e-e89b-8d02-6ee2915cb645_6	-7.782702	110.357426	2022-02-20 14:14:47

Gambar 4.3. Sampel data GPS setelah dilakukan *split trajectory*

Setelah proses pemisahan dengan *split trajectory* dilakukan, dilakukan proses rekonstruksi rute perjalanan menggunakan metode *path reconstruction*. Metode ini bertujuan untuk merekonstruksi rute perjalanan pengguna dengan membangun jalur rute perjalanan pengguna berdasarkan titik-titik GPS yang ada. Dengan memanfaatkan *library* PyTrack, dilakukan rekonstruksi rute perjalanan pada setiap satuan *trajectory*.

Seperti digambarkan pada Gambar 4.4, ditampilkan salah satu *trajectory* yang terbentuk berdasarkan titik-titik GPS yang ada. Pada gambar tersebut, titik hitam merepresentasikan titik GPS sedangkan lingkaran abu-abu merupakan kandidat titik-titik yang akan membentuk rute perjalanan. Dari kandidat tersebut kemudian terbentuk trellis diagram yang merupakan penggambaran semua kemungkinan transisi antara kandidat dari satu titik GPS ke titik berikutnya, dengan setiap transisi diberi bobot berdasarkan probabilitasnya. Probabilitas ini dihitung menggunakan algoritma HMM, yang memperimbangan faktor-faktor seperti jarak antar kandidat dan kesesuaian arah pergerakan. Dengan trellis diagram yang telah dibangun, PyTrack kemudian menerapkan algoritma



Gambar 4.4. Proses rekonstruksi rute perjalanan dengan *library* PyTrack

Viterbi untuk menemukan jalur terbaik melalui semua kandidat. Hasil jalur terbaik ini di-representasikan dengan garis hijau yang kemudian dapat menjadi lintasan atau *trajectory* yang dapat dilakukan analisis lebih lanjut.

Pada Tabel 4.2 terlihat beberapa sampel *trajectory* hasil rekonstruksi rute perjalanan menggunakan *path reconstruction*. Terdapat 4 *trajectory* yang terbentuk, yaitu *trajectory* 0, 1, 4, dan 6. Setiap *trajectory* memiliki titik GPS awal dan titik GPS hasil rekonstruksi rute perjalanan. Dari hasil ini, DataFrame yang dihasilkan terdiri dari *maid* dan titik GPS yang membentuk rute perjalanan pengguna (Gambar 4.6). DataFrame ini belum dapat digunakan untuk menghitung kecepatan dan arus lalu lintas karena belum memiliki informasi waktu di setiap titiknya. Oleh karena itu, data ini masih harus diproses lebih lanjut menggunakan interpolasi waktu untuk mendapatkan nilai waktu di setiap titiknya.

	maid_trajectory	adjusted_way_latitude	adjusted_way_longitude	timestamp
0	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.790907	110.366080	2022-02-14 13:17:24
1	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.793937	110.364967	2022-02-14 13:18:46
2	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.793513	110.361309	2022-02-14 13:20:08
3	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.793027	110.356609	2022-02-14 13:21:29

Gambar 4.5. Sampel DataFrame titik GPS awal

Proses interpolasi waktu dilakukan untuk mengisi nilai waktu pada titik-titik GPS baru yang dihasilkan dari rekonstruksi rute perjalanan. Proses ini melibatkan dua DataFrame, yaitu DataFrame hasil rekonstruksi rute perjalanan (Gambar 4.6) dan DataFrame titik-titik GPS awal yang memiliki fitur *timestamp* (Gambar 4.5). Kedua DataFrame ter-

	maid_trajectory	latitude	longitude
0	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.781798	110.373925
1	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.781791	110.373787
2	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.781784	110.373649
3	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.781777	110.373510
4	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.781769	110.373372

Gambar 4.6. Sampel DataFrame hasil rekonstruksi rute perjalanan

sebut kemudian diolah dengan metode interpolasi linear berdasarkan jarak waktu observasi serta jumlah titik baru yang terbentuk dari rekonstruksi rute perjalanan.

Pada contoh di Gambar 4.5, terdapat 2 titik GPS $t_0(-7.790907, 110.366080)$ dan $t_1(-7.793937, 110.364967)$ yang diantaranya terbentuk 27 titik baru. Dua titik ini memiliki jarak antar waktu observasi 1 menit 22 detik atau sekitar 82 detik. Dari nilai tersebut kemudian dilakukan perhitungan δt , seperti ditampilkan pada Persamaan 4-1.





$$\delta t = \frac{\Delta t}{n + 1} = \frac{82}{27 + 1} = 2,92 \approx 3,00 \text{ detik} \quad (4-1)$$

Dengan nilai δt yang telah didapatkan, kemudian dilakukan interpolasi waktu untuk mengisi *timestamp* pada titik-titik GPS baru yang dihasilkan dari rekonstruksi rute perjalanan. Proses ini dilakukan dengan menghitung waktu observasi pada setiap titik GPS baru dengan menambahkan δt pada waktu observasi titik GPS sebelumnya sesuai dengan urutan titik GPS baru yang dihasilkan. Proses ini dilakukan untuk setiap titik GPS baru yang dihasilkan dari rekonstruksi rute perjalanan tiap *trajectory*. Setelah semua *trajectory* selesai diproses, dihasilkan DataFrame yang memiliki fitur *timestamp* yang telah diisi dengan waktu observasi yang sesuai (Gambar 4.7). DataFrame ini kemudian dapat digunakan untuk menghitung kecepatan dan arus.

	maid_trajectory	latitude	longitude	timestamp
0	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.790875	110.366084	2022-02-14 13:17:24
1	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.791013	110.366068	2022-02-14 13:17:27
2	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.791151	110.366052	2022-02-14 13:17:30
3	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.791293	110.366036	2022-02-14 13:17:33
4	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.791423	110.366021	2022-02-14 13:17:36
5	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.791553	110.366007	2022-02-14 13:17:39
6	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.791683	110.365992	2022-02-14 13:17:41
7	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.791816	110.365976	2022-02-14 13:17:44
8	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.791954	110.365961	2022-02-14 13:17:47
9	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.792088	110.365946	2022-02-14 13:17:50
10	0229383e-383e-e89b-8d02-6ee2915cb645_1	-7.792216	110.365934	2022-02-14 13:17:53

Gambar 4.7. Sampel DataFrame setelah rekonstruksi rute perjalanan dan interpolasi waktu

Tabel 4.2. Sampel hasil implementasi *split trajectory* dan *path reconstruction*


<i>Trajectory</i>	0229383e-383e-e89b-8d02-6ee2915cb645_0	0229383e-383e-e89b-8d02-6ee2915cb645_1	0229383e-383e-e89b-8d02-6ee2915cb645_4	0229383e-383e-e89b-8d02-6ee2915cb645_6
Titik GPS Awal				
Titik GPS Hasil Rekonstruksi Rute Perjalanan				

4.2 Analisis Pola Kecepatan dan Arus Lalu Lintas

Subbab ini merupakan hasil dari rumusan masalah yang kedua, yaitu tentang mengidentifikasi pola kecepatan dan arus lalu lintas di Jalan Malioboro. Pada tahap ini, penulis melakukan analisis pola kecepatan dan arus lalu lintas dengan memanfaatkan dataset hasil rekonstruksi rute perjalanan yang telah dilakukan sebelumnya. Analisis ini bertujuan untuk mengetahui pola kecepatan dan arus lalu lintas berdasarkan tren waktu tertentu. Subbab ini terdiri dari 3 bagian, yaitu perhitungan kecepatan dan arus, analisis pola kecepatan, serta analisis pola arus.

4.2.1 Perhitungan Kecepatan dan Arus Lalu Lintas

Proses perhitungan kecepatan dan arus lalu lintas dilakukan dengan menggunakan dataset rekonstruksi rute perjalanan tiap *trajectory* yang telah memiliki informasi waktu atau *timestamp* di setiap titiknya. Proses ini dilakukan untuk mendapatkan rata-rata estimasi kecepatan dan arus sebelum hasilnya dapat dilakukan proses analisis. Sebelum dilakukan perhitungan, terlebih dahulu dilakukan pengambilan titik GPS yang berada dalam lingkup Jalan Malioboro saja. Hal ini dilakukan dengan membuat poligon *buffer* sepanjang Jalan Malioboro, mulai dari Plang Malioboro hingga Titik Nol dengan lebar *buffer* sebesar lebar jalan, yaitu 5 meter.



Gambar 4.8. Poligon *buffer* dan kumpulan titik GPS yang berada di Jalan Malioboro

Sebagai gambaran, terlihat pada Gambar 4.8 terdapat poligon yang melingkupi Jalan Malioboro dan titik-titik GPS yang berada di dalam poligon tersebut. Dalam pengambilan titik ini tidak perlu mengkhawatirkan apabila terdapat titik rute yang berada di luar poligon dan mungkin mengakibatkan hasil perhitungan yang tidak valid, hal ini dikarenakan proses *preprocessing* sebelumnya sudah memastikan bahwa titik rute pasti

berada di dalam jaringan jalan, sehingga tidak ada titik yang berada di luar poligon yang akan masuk pada target perhitungan di Jalan Malioboro. Dari proses ini tersisa 200.254 titik GPS yang terdiri dari 5.354 *trajectory* yang berada di dalam poligon Jalan Malioboro (Tabel 4.3).

Tabel 4.3. Perubahan jumlah titik GPS dan *trajectory* pada setiap tahap

	<i>Split Trajectory</i>	Rekonstruksi Rute Perjalanan	Lingkup Jalan Malioboro	Perhitungan Kecepatan
Jumlah Titik Data GPS	175.964	4.231.096	200.254	-
Jumlah Trajectory	30.482	29.058	5.354	2.316

Berikutnya setelah titik-titik GPS yang berada di dalam poligon Jalan Malioboro didapatkan, dilakukan perhitungan kecepatan dan arus lalu lintas. Perhitungan kecepatan dilakukan dengan menghitung jarak antar titik GPS yang berada di dalam poligon Jalan Malioboro dan membagi hasilnya dengan selisih waktu. Namun, hanya *trajectory* yang memenuhi kriteria saja yang akan dihitung kecepataannya. Kriteria tersebut adalah *trajectory* yang memiliki minimal 2 titik GPS dan arahnya sesuai dengan arah Jalan Malioboro yang satu arah. Perhitungan ini dilakukan untuk setiap *trajectory* yang melewati Jalan Malioboro. Rata-rata kecepatan dihitung dengan menjumlahkan semua kecepatan yang didapatkan dari setiap *trajectory* dan membaginya dengan jumlah *trajectory*. Seperti ditampilkan pada Tabel 4.3, tersisa sebanyak 2.316 *trajectory* yang berarti sekitar 43,2% data di dalam lingkup Jalan Malioboro memenuhi kriteria untuk dapat dilakukan perhitungan kecepatan. Sisa data yang tidak masuk ini kemungkinan besar terjadi karena *trajectory* tersebut memiliki arah pergerakan yang berlawanan atau hanya melewati sebagian kecil dari Jalan Malioboro sehingga kecepatan yang didapatkan tidak memenuhi kriteria target.

Serangkaian proses perhitungan kecepatan menghasilkan data kecepatan untuk setiap *trajectory*. Pada Gambar 4.9 ditampilkan DataFrame hasil perhitungan kecepatan yang terdiri dari 7 fitur. Penjelasan setiap fitur dapat dilihat pada Tabel 4.4. Data ini kemudian dapat digunakan untuk menjadi bahan analisis pola kecepatan lalu lintas di Jalan Malioboro berdasarkan tren waktu tertentu.

Perhitungan arus dicari berdasarkan jumlah *trajectory* yang melewati ruas Jalan Malioboro berdasarkan waktu-waktu tertentu. Jumlah ini diperoleh dari DataFrame yang sama dengan data kecepatan yang ditampilkan pada Gambar 4.9. Data yang sama digunakan karena data kecepatan tersebut sudah memenuhi kriteria untuk dihitung sebagai

	maid_trajectory	start_t	end_t	distance	duration	speed	bearing
0	01b75026-0e33-4a15-b4c4-65a7afa9c6dd_1	2022-01-27 14:26:27	2022-01-27 14:28:17	159.106734	110.0	5.207129	187.525450
1	028de778-c3b6-4993-9f4c-339b33be244b_12	2022-01-23 21:10:28	2022-01-23 21:13:34	1144.872354	186.0	22.158820	187.294208
2	028de778-c3b6-4993-9f4c-339b33be244b_22	2022-01-30 06:53:13	2022-01-30 06:53:27	75.662167	14.0	19.455986	188.600972
3	037f2975-7566-4ce6-8860-8db2228c3cdf_8	2022-01-31 01:24:43	2022-01-31 01:28:42	1144.872354	239.0	17.244939	187.294208
4	0419eb09-110d-435e-9b9f-a697ab3567fc_10	2022-01-24 06:27:58	2022-01-24 06:29:09	323.084094	71.0	16.381729	186.816276
...	...	...	...	...	...	...	...
2311	fef875c4-75c4-e206-a81c-93417f21ccbf_3	2022-02-18 17:31:13	2022-02-18 17:35:23	700.704046	250.0	10.090138	188.600971
2312	fef875c4-75c4-e206-a81c-93417f21ccbf_7	2022-02-18 21:46:51	2022-02-18 21:48:15	209.436886	84.0	8.975867	187.294208
2313	ff123993-3993-5d61-a8a2-af4449ea0453_1	2022-02-06 11:46:32	2022-02-06 11:49:16	594.155317	164.0	13.042434	186.602365
2314	ff78ab4b-bf24-461e-b3d8-eca84e05d3cd_0	2022-02-17 12:18:34	2022-02-17 12:22:13	910.217957	219.0	14.962487	187.362166
2315	ffc55c5a-e344-4110-a242-67b98f410f11_3	2022-02-08 14:13:54	2022-02-08 14:15:07	192.639096	73.0	9.500010	187.294207

Gambar 4.9. DataFrame hasil perhitungan kecepatan lalu lintas

Tabel 4.4. Fitur DataFrame hasil perhitungan kecepatan lalu lintas

Fitur	Deskripsi	Tipe Data
<i>maid_trajectory</i>	ID unik yang merepresentasikan setiap perjalanan pengguna	object
<i>start_t</i>	Waktu observasi titik GPS awal	datetime64
<i>end_t</i>	Waktu observasi titik GPS akhir	datetime64
<i>distance</i>	Jarak yang ditempuh dari titik GPS awal hingga akhir dalam satuan meter	float64
<i>duration</i>	Durasi yang ditempuh dari titik GPS awal hingga akhir dalam satuan detik	float64
<i>speed</i>	Kecepatan dari perjalanan yang didapatkan dari $\frac{\text{jarak}}{\text{waktu}}$, dalam satuan km/jam	float64
<i>bearing</i>	Arah pergerakan dari titik GPS dalam satuan derajat	float64

objek yang berkontribusi terhadap arus lalu lintas di Jalan Malioboro. Dengan menggunakan DataFrame yang sama, analisis arus menjadi lebih konsisten dan akurat karena semua data diambil dari sumber yang seragam. Setiap *trajectory* yang tercatat pada data kecepatan dianggap sebagai entitas yang berpengaruh terhadap lalu lintas, sehingga memastikan bahwa perhitungan arus mencakup semua variabel yang relevan. Hasil perhitungan arus ini lengkapnya akan dijelaskan pada bagian 4.2.3 Analisis Pola Arus.

4.2.2 Analisis Pola Kecepatan Lalu Lintas

Tahap ini melakukan analisis pola kecepatan lalu lintas di Jalan Malioboro menggunakan dataset hasil perhitungan kecepatan seperti yang terlihat pada Gambar 4.9. Analisis deskriptif dari data kecepatan dapat dilihat pada Table 4.5. Dari data tersebut, rata-rata kecepatan lalu lintas di Jalan Malioboro adalah 14,51 km/jam, dengan standar deviasi sebesar 6,59 km/jam. Kecepatan tertinggi yang mencapai 29,36 km/jam, sementara kecepatan terendah hanya 5,01 km/jam. Data ini menunjukkan bahwa kecepatan rata-rata lalu lintas di Jalan Malioboro cenderung rendah, yang kemungkinan disebabkan oleh volume

kendaraan yang tinggi di jalan ini, mengingat Jalan Malioboro merupakan tujuan wisata yang populer.


Statistik	Nilai
<i>Mean</i>	14,50833356
<i>Median</i>	13,37657108
<i>Mode</i>	26,74386588
<i>Standard Deviation</i>	6,589543023
<i>Kurtosis</i>	-0,881514461
<i>Skewness</i>	0,485364388
<i>Minimum</i>	5,006888486
<i>Maximum</i>	29,36402852
<i>Count</i>	2.316

Tabel 4.5. Statistik deskriptif kecepatan lalu lintas


Analisis lebih lanjut pada distribusi data kecepatan ditunjukkan dengan nilai *kurtosis* sebesar -0,88 dan *skewness* sebesar 0,48. Nilai *kurtosis* yang negatif menunjukkan bahwa distribusi kecepatan cenderung lebih datar dibandingkan dengan distribusi normal, dengan ekor distribusi yang tidak terlalu panjang. Sedangkan *skewness* yang positif menunjukkan bahwa distribusi kecepatan memiliki condongan ke arah kecepatan yang lebih tinggi atau kanan. Hasil ini juga terlihat dari histogram kecepatan yang tergambar pada Gambar 4.10. Meskipun pada pandangan sekilas histogram terlihat condong ke kiri, tetapi frekuensi untuk kecepatan 26-27 km/jam memiliki jumlah yang signifikan dibandingkan dengan kecepatan lainnya. Hal ini yang membuat distribusi data kecepatan cenderung condong ke arah kanan. Lonjakan frekuensi pada kecepatan 26-27 km/jam ini mungkin disebabkan oleh adanya periode di mana kendaraan dapat bergerak lebih cepat, seperti pada jam-jam tertentu di mana volume jalan lebih rendah.

Tertampil pula histogram distribusi data kecepatan berdasarkan kategori hari kerja dan akhir pekan pada Gambar 4.11. Pada penelitian ini, kategori hari kerja merujuk pada hari Senin hingga Jumat, sedangkan kategori akhir pekan merujuk pada hari Sabtu dan Minggu. Pada hari kerja, kecepatan kendaraan tersebar luas dari sekitar 5 km/jam hingga mendekati 30 km/jam, dengan puncak frekuensi tinggi pada *range* 26-27 km/jam. Sebaliknya, pada akhir pekan, kecepatan kendaraan lebih terpusat pada rentang 5-10 km/jam, dengan penurunan frekuensi yang cepat setelah 10 km/jam, sama seperti hari kerja terdapat lonjakan frekuensi pada kecepatan 26 km/jam. Mayoritas kendaraan bergerak lebih lambat pada akhir pekan, diduga disebabkan oleh peningkatan volume pejalan kaki dan kendaraan parkir di sepanjang jalan yang sering terjadi di kawasan wisata.

Untuk melihat perubahan kecepatan secara lebih rinci, dilakukan visualisasi *heatmap* seperti yang ditampilkan pada Gambar 4.12. Pada visualisasi ini, setiap baris




Gambar 4.10. Histogram distribusi data kecepatan bulan Januari-Februari 2022



Gambar 4.11. Histogram distribusi data kecepatan berdasarkan kategori hari kerja dan akhir pekan

merepresentasikan kategori hari, setiap kolom merepresentasikan waktu interval 30 menit, dan setiap *cell* merepresentasikan *time bin* yang menyimpan rerata nilai kecepatan. Warna dari setiap *cell* menunjukkan rata-rata kecepatan, merah merepresentasikan kecepatan rendah, sedangkan hijau merepresentasikan kecepatan tinggi. Untuk *cells* yang tidak memiliki data ditampilkan dengan warna abu-abu.

Dari visualisasi *heatmap*, nampak bahwa rata-rata kecepatan lalu lintas di Jalan Malioboro cenderung lebih tinggi pada hari kerja, dengan rata-rata hari kerja sebesar 15,54 km/jam sedangkan pada akhir pekan 12,88 km/jam. Pada hari kerja, kecepatan puncak tertinggi ada di pagi hari, terlihat dari *cell* berwarna hijau antara pukul 06.00-08.00, dengan kecepatan tertinggi mencapai 28 km/jam. Hasil ini diduga mengindikasikan bahwa lalu lintas di Jalan Malioboro tidak terlalu dipengaruhi oleh jam sibuk pagi, tidak seperti jalan-jalan lain yang biasanya lebih lambat karena mayoritas masyarakat mela-



Gambar 4.12. *Heatmap* rata-rata distribusi kecepatan berdasarkan hari dan jam

kukan mobilitas untuk bekerja atau sekolah pada pagi hari. Kecepatan perlahan menurun pada siang hari dan mencapai puncak penurunan di sore hari pada pukul 15.00-18.00, dengan kecepatan terendah mencapai 9,7 km/jam. Penurunan ini diduga disebabkan oleh peningkatan arus lalu lintas pada jam sibuk sore. Walaupun Jalan Malioboro tidak terpengaruh oleh jam sibuk pagi, hasil yang didapatkan menunjukkan bahwa Jalan Malioboro mengalami lonjakan yang cukup signifikan pada sore hari. Hal ini diduga disebabkan oleh karakteristik Jalan Malioboro sebagai jalan satu arah (utara ke selatan) yang menyebabkan peningkatan mobilitas pada sore hari ketika banyak orang kembali dari pusat lokasi perkantoran atau pendidikan di bagian utara Kota Yogyakarta menuju rumahnya di bagian selatan. Sebagai salah satu rute utama, Jalan Malioboro kerap digunakan sebagai jalur untuk perjalanan pulang. Hal ini mungkin dapat menjelaskan mengapa kecepatan di Jalan Malioboro cenderung menurun pada sore hari. Saat malam hari, kecepatan kembali meningkat. Hal ini diduga karena Jalan Malioboro menerapkan kebijakan *Car Free Night* (CFN) setiap harinya pada pukul 18.00-21.00. Kebijakan ini melarang kendaraan bermotor untuk masuk di Jalan Malioboro. Kebijakan ini juga menjelaskan mengapa banyak data tidak tersedia pada jam-jam tersebut. Namun, bukan berarti tidak ada mobilitas sama sekali pada jam tersebut, karena angkutan umum seperti Trans Jogja serta moda transportasi tradisional seperti becak, sepeda kayuh, dan andong masih diperbolehkan melintas, meski jumlahnya tidak sebanyak kendaraan bermotor.


Sementara itu, pada akhir pekan, pola kecepatan lalu lintas di Jalan Malioboro menunjukkan variasi yang berbeda dibandingkan hari kerja. Pada pagi hari, kecepatan cenderung tinggi, dengan kecepatan tertinggi mencapai 28 km/jam pada pukul 06.00-08.00. Namun, tidak lama kemudian, menjelang siang hari kecepatan mulai menurun hingga kecepatan terendah terjadi pada pukul 15.00-18.00 mencapai 6 km/jam. Menjelang malam hari, pola kecepatan akhir pekan cenderung tidak dapat diprediksi. Berbeda dengan kondisi pada hari kerja yang relatif lebih tinggi, kecepatan pada akhir pekan relatif tidak stabil dan bervariasi. Hal ini mungkin disebabkan oleh berbagai faktor, seperti peningkatan volume kendaraan wisatawan, aktivitas rekreasi, dan acara khusus yang sering terjadi pada akhir pekan.

Dalam analisis ini, terdapat pula beberapa *outlier* atau data kecepatan yang tidak sesuai dengan pola umum. Misalnya, kecepatan yang sangat tinggi atau sangat rendah

pada waktu tertentu yang muncul secara sporadis. *Outlier* ini mungkin disebabkan oleh berbagai faktor yang tidak selalu terkait dengan volume lalu lintas. Contohnya seperti peristiwa khusus, kondisi jalan, cuaca, keputusan pengemudi, atau faktor lain yang tidak dapat diprediksi. Penulis mengakui adanya *outlier* dan ketidakpastian ini, karena data kecepatan yang digunakan dalam analisis ini bersifat agregat dan tidak memperhitungkan faktor-faktor tersebut. Mengakui adanya *outlier* dan ketidakpastian ini dilakukan untuk menghindari generalisasi berlebihan dari hasil analisis.

4.2.3 Analisis Pola Arus Lalu Lintas

Analisis selanjutnya merupakan analisis pola arus lalu lintas di Jalan Malioboro. Analisis ini dilakukan dengan menggunakan data kecepatan (Gambar 4.9) yang dihitung berdasarkan jumlah *trajectory* yang melewati Jalan Malioboro setiap jamnya. Pada Gambar 4.13 ditampilkan *line chart* rata-rata perubahan arus dalam sehari berdasarkan kategori hari kerja dan akhir pekan, dengan area bayangan menggambarkan standar deviasi untuk masing-masing kategori.



Gambar 4.13. *Line chart* perubahan arus berdasarkan kategori hari kerja dan akhir pekan

Pada hari kerja, rata-rata arus lalu lintas lebih tinggi dibandingkan dengan akhir pekan. Arus lalu lintas pada hari kerja meningkat secara bertahap dari pukul 06.00 hingga mencapai puncaknya sekitar pukul 15.00. Setelah melewati puncak, terjadi penurunan arus yang signifikan pada pukul 18.00. Penurunan ini mungkin disebabkan oleh kebijakan CFN yang menyebabkan penurunan volume kendaraan bermotor yang melintas pada malam hari. Meskipun demikian, masih terdapat arus lalu lintas yang terdeteksi, karena masih terdapat angkutan umum dan moda transportasi tradisional yang masih beroperasi. Selain itu, visualisasi juga menunjukkan bahwa pada hari kerja, standar deviasi cen-

derung lebih rendah dibandingkan dengan akhir pekan dengan rata-rata standar deviasi sebesar 3,75. Hal ini menunjukkan bahwa arus lalu lintas pada hari kerja lebih konsisten setiap harinya, dengan fluktuasi yang lebih kecil. Konsistensi ini mungkin disebabkan oleh pola perjalanan yang teratur dan dapat diprediksi, seperti aktivitas berangkat dan pulang kerja atau sekolah yang terjadi pada waktu yang sama setiap hari.

Sementara itu, pada akhir pekan, pola arus lalu lintas tidak jauh berbeda dengan hari kerja. Akan tetapi, terdapat perbedaan pada pukul 09.00-17.00 dengan tingkat arus yang lebih rendah. Standar deviasi pada akhir pekan memiliki nilai yang lebih tinggi dibandingkan hari kerja, dengan nilai 4,97. Hal ini menunjukkan variabilitas arus lalu lintas yang cukup besar antar harinya. Standar deviasi tertinggi terjadi pada sore hari sekitar pukul 14.00-16.00, mencerminkan fluktuasi yang cukup besar pada periode ini. Arus lalu lintas yang lebih bervariasi pada akhir pekan menunjukkan bahwa terdapat berbagai faktor yang mempengaruhi pola lalu lintas pada akhir pekan, seperti berbagai aktivitas rekreasi, wisata, dan acara khusus yang tidak terjadi di hari kerja.

4.3 Perbandingan Hasil Analisis Pola Lalu Lintas dengan Data *Ground Truth*

Subbab ini merupakan hasil dari rumusan masalah yang ketiga, yaitu perbandingan hasil analisis dengan keadaan yang sesungguhnya atau *ground truth*. Pada subbab ini, penulis membandingkan hasil analisis kecepatan dan arus lalu lintas di Jalan Malioboro menggunakan MPD aktif dengan data kecepatan dan arus lalu lintas yang diperoleh dari sumber *ground truth*, yaitu data kecepatan dan arus lalu lintas yang diperoleh dari Google Maps dan Dinas Perhubungan DIY.


4.3.1 Perbandingan Kecepatan Lalu Lintas dengan Data Google Maps

Analisis perbandingan data kecepatan MPD aktif dan Google Maps dilakukan dengan metode *Dynamic Time Warping* (DTW) serta koefisien Korelasi Pearson. Metode DTW menghasilkan jarak DTW yang menunjukkan beban yang dibutuhkan untuk menyesuaikan data kecepatan MPD aktif dengan data kecepatan Google Maps. Semakin kecil jarak DTW yang diperlukan maka semakin mirip kedua data tersebut. Hasil perhitungan menggunakan DTW ditampilkan pada Tabel 4.6. Pada hasil ini, penulis membagi perhitungan menjadi setiap kategori hari untuk melihat bagaimana data bersesuaian setiap harinya.

Hasil menunjukkan bahwa jarak DTW bervariasi antara hari-hari yang berbeda, Sabtu memiliki kesesuaian terbaik dengan jarak 33,36 sedangkan Rabu memiliki kesesuaian terburuk dengan jarak sebesar 65,48. Apabila dilihat dari kategori yang lebih umum pada Tabel 4.7, akhir pekan memiliki jarak DTW yang lebih rendah dibandingkan hari kerja. Hal ini menunjukkan bahwa data kecepatan MPD aktif pada akhir pekan lebih sesuai dengan data kecepatan Google Maps dibandingkan hari kerja.

Hari	Jarak DTW
Senin	37,37
Selasa	37,94
Rabu	65,48
Kamis	37,97
Jumat	56,13
Sabtu	33,36
Minggu	40,85

Tabel 4.6. Hasil perhitungan jarak DTW untuk perbandingan kecepatan per hari



Gambar 4.14. *Line chart* perbandingan kecepatan dengan Google Maps


Untuk lebih memahami perbandingan ini, penulis juga membuat visualisasi *line chart* pada Gambar 4.14. Visualisasi ini dapat memberikan gambaran yang lebih jelas tentang pola kecepatan antara kedua sumber data. Terlihat pada hari-hari dengan jarak DTW tinggi, seperti hari Rabu dan Jumat, *line chart* menunjukkan perbedaan signifikan antara kedua set data. Pada hari-hari tersebut, data MPD aktif kerap menunjukkan fluktuasi yang lebih besar dibandingkan dengan data dari Google Maps. Sebaliknya, hari-hari dengan jarak DTW rendah, seperti Sabtu dan Senin, menunjukkan pola yang lebih mirip antara kedua sumber data. Pada hari-hari ini, perbedaan kecepatan antara data MPD dan Google Maps lebih kecil, menunjukkan kesesuaian yang lebih baik.

Selanjutnya, untuk menilai kesesuaian antara data kecepatan MPD aktif dan Google Maps secara lebih objektif, koefisien Korelasi Pearson dihitung dan menghasilkan hasil pada Tabel 4.7. Nilai ini menunjukkan adanya hubungan linear yang lebih baik pada akhir pekan, sedangkan keseluruhannya sebesar 0,52 yang berarti terdapat kesesuaian yang sedang antara data kecepatan dan Google Maps, tetapi tidak sempurna. Seperti tertampil pada *scatter plot* pada Gambar 4.15, visualisasi ini menunjukkan bahwa data kecepatan MPD aktif memiliki hubungan yang positif dengan data Google Maps, meskipun terdapat variasi yang cukup beragam terutama pada hari kerja.

Secara keseluruhan, meskipun data MPD aktif bisa memberikan estimasi yang cukup baik tentang tren umum kecepatan, masih terdapat variabilitas dan beberapa kesalahan yang menunjukkan perlunya peningkatan dalam metode pengumpulan atau pe-

Kategori Hari	Jarak DTW	Korelasi Pearson
Hari Kerja	46,97	0,29 (korelasi positif lemah)
Akhir Pekan	37,10	0,63 (korelasi positif sedang)
Keseluruhan	-	0,52 (korelasi positif sedang)

Tabel 4.7. Hasil perbandingan kecepatan dengan data Google Maps



Gambar 4.15. *Scatter plot* perbandingan kecepatan dengan data Google Maps

ngolahan data MPD aktif. Beberapa titik data dari MPD aktif menunjukkan kecepatan yang sangat tinggi atau rendah yang tidak terpantau oleh Google Maps, mengindikasikan adanya *outlier* pada hasil analisis dengan MPD aktif.

4.3.2 Perbandingan Arus Lalu Lintas dengan Data Dinas Perhubungan DIY

Analisis perbandingan selanjutnya merupakan perbandingan arus lalu lintas di Jalan Malioboro dengan data arus lalu lintas yang diperoleh dari Dinas Perhubungan DIY. Sama seperti kecepatan, perbandingan ini dilakukan dengan metode *Dynamic Time Warping* (DTW) serta koefisien Korelasi Pearson. Hasil perhitungan menggunakan DTW ditampilkan pada Tabel 4.8. Perbandingan ini disesuaikan dengan ketersediaan data dari Dinas Perhubungan DIY yang membagi data arus berdasarkan kategori hari kerja dan akhir pekan.

Data yang dibandingkan telah dinormalisasi terlebih dahulu sehingga nilainya berada dalam rentang 0 hingga 1. Normalisasi ini dilakukan untuk memastikan kedua dataset memiliki skala yang sama sehingga proses DTW dapat lebih akurat. Pada hari kerja, total jarak DTW yang diperlukan adalah 1,15. Sementara itu, pada akhir pekan, total jarak DTW lebih tinggi yaitu 1,9, yang menunjukkan perbedaan yang lebih besar dalam pola arus antara kedua dataset selama akhir pekan.


Gambar 4.16 menampilkan *scatter plot* untuk perbandingan hari kerja dan akhir pekan. *Scatter plot* hari kerja menunjukkan adanya korelasi positif yang kuat antara data MPD aktif dan data Dinas Perhubungan DIY. Ini berarti bahwa ketika hasil estimasi arus MPD aktif meningkat, arus yang tercatat oleh Dinas Perhubungan DIY juga mening-

kat. Hubungan ini ditunjukkan oleh garis regresi linear merah yang memiliki kemiringan tajam dan titik-titik data yang berada dekat dengan garis tersebut.

Pada *scatter plot* akhir pekan, meskipun masih terdapat korelasi positif, hubungan ini lebih lemah dibandingkan dengan hari kerja. Hal ini ditunjukkan oleh garis regresi linear yang lebih datar dan titik-titik data yang lebih tersebar. Hasil Korelasi Pearson untuk akhir pekan adalah 0,44, menunjukkan korelasi yang sedang. Korelasi ini lebih lemah dibandingkan hari kerja, mencerminkan variasi perbedaan yang lebih besar selama akhir pekan. Secara keseluruhan, terdapat hubungan sebesar 0,58 yang berarti ada kesesuaian yang sedang antara data arus dari MPD aktif dan Dinas Perhubungan DIY, tetapi tidak sempurna.

Kategori Hari	Jarak DTW	Korelasi Pearson
Hari Kerja	1,15	0,79 (korelasi positif kuat)
Akhir Pekan	1,9	0,44 (korelasi positif sedang)
Keseluruhan	-	0,58 (korelasi positif sedang)

Tabel 4.8. Hasil perbandingan arus dengan data Dinas Perhubungan DIY



Gambar 4.16. *Scatter plot* perbandingan arus dengan data Dinas Perhubungan DIY

Dari kedua metode perbandingan ini, dapat disimpulkan bahwa data arus dari MPD aktif memiliki pola yang cukup mirip dengan data dari Dinas Perhubungan DIY, terutama pada hari kerja seperti yang ditunjukkan oleh jarak DTW yang lebih kecil dan Korelasi Pearson sebesar 0,79 yang menunjukkan hubungan yang kuat. Pada akhir pekan, meskipun masih terdapat hubungan positif, pola perubahan arus lebih bervariasi dan tidak sekuat pada hari kerja.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Pada penelitian ini telah dilakukan analisis deskriptif terhadap *time series* data GPS berdasarkan data MPD aktif untuk mengidentifikasi pola kecepatan dan arus lalu lintas di Jalan Malioboro. Analisis dilakukan dengan rekonstruksi rute perjalanan dan dievaluasi dengan membandingkan hasilnya dengan data *ground truth*. Dari penelitian ini, telah tercapai semua tujuan yang telah ditetapkan serta diperoleh kesimpulan sebagai berikut:

1. Rekonstruksi rute perjalanan pengguna di Jalan Malioboro menggunakan data MPD aktif berhasil dilakukan dengan metode *path reconstruction* dan interpolasi waktu, dimana rute perjalanan pengguna direkonstruksi berdasarkan titik lokasi dan waktu. Metode ini melibatkan proses transformasi dan manipulasi data untuk memastikan akurasi hasil. Dengan pendekatan ini, berhasil dihasilkan sebanyak 2.316 satuan rute perjalanan pengguna yang dapat dilakukan analisis lebih lanjut.
2. Pola kecepatan dan arus lalu lintas di Jalan Malioboro berhasil diidentifikasi menggunakan hasil rekonstruksi rute perjalanan pengguna. Ditemukan bahwa pola kecepatan dan arus lalu lintas di Jalan Malioboro memiliki pola yang berbeda pada hari kerja dan akhir pekan. Kecepatan rata-rata pada hari kerja lebih tinggi dibandingkan akhir pekan, dengan kecepatan tertinggi sama-sama terjadi pada pagi hari dan kecepatan terendah sama-sama terjadi pada sore hari. Namun, perbedaan terdapat pada pola kecepatan di akhir pekan, dimana kecepatan cenderung relatif lebih rendah sepanjang hari. Sementara itu, pola arus pada hari kerja dan akhir pekan memiliki pola yang serupa, dengan arus tertinggi sama-sama terjadi pada sore hari. Akan tetapi, perbedaan pola arus terdapat pada pukul 09.00-17.00, dimana arus pada akhir pekan cenderung lebih rendah dibandingkan arus pada hari kerja.
3. Evaluasi hasil identifikasi pola kecepatan dan arus lalu lintas di Jalan Malioboro dilakukan dengan membandingkan dengan data *ground truth* menggunakan metode *Dynamic Time Warping* (DTW) dan koefisien Korelasi Pearson. Perbandingan kecepatan lalu lintas menunjukkan bahwa tingkat kesesuaian terbaik terjadi pada hari Sabtu, sementara kesesuaian terburuk terjadi pada hari Rabu. Kesesuaian kecepatan pada akhir pekan lebih baik dibandingkan hari kerja, dengan keseluruhan pola memiliki tingkat kesesuaian yang sedang dengan nilai Korelasi Pearson 0,52. Sementara itu, perbandingan arus lalu lintas menunjukkan bahwa tingkat kesesuaian pada hari kerja lebih baik dibandingkan akhir pekan, dengan keseluruhan pola

menunjukkan tingkat kesesuaian yang sedang dengan nilai Korelasi Pearson 0,58. Dari hasil ini, dapat disimpulkan bahwa estimasi kecepatan dan arus lalu lintas memberikan gambaran yang cukup baik mengenai kondisi lalu lintas di Jalan Malioboro. Penelitian ini menunjukkan bahwa data yang diperoleh dari MPD aktif dapat memberikan estimasi yang cukup akurat, tetapi dengan tingkat keakuratan yang bervariasi tergantung pada hari dan waktu tertentu. Oleh karena itu, evaluasi lebih lanjut diperlukan untuk memahami variabilitas yang lebih mendalam serta faktor-faktor lain yang mungkin memengaruhi hasil estimasi.

5.2 Saran

Saran yang dapat diberikan untuk penelitian selanjutnya adalah sebagai berikut:

1. Meskipun rekonstruksi rute perjalanan pengguna dapat dilakukan menggunakan metode *path reconstruction*, data hasil rekonstruksi belum dilakukan evaluasi dari segi akurasi. Penelitian selanjutnya dapat melakukan evaluasi terhadap metode dan hasil yang didapatkan sebelum melanjutkan pada tahap analisis, hal ini berguna untuk memastikan keakuratan hasil analisis. Selain itu, penelitian selanjutnya juga dapat mempertimbangkan metode rekonstruksi rute perjalanan lain yang mungkin lebih sesuai dengan karakteristik data MPD aktif.
2. Analisis lebih lanjut terhadap pola kecepatan dan arus lalu lintas di Jalan Malioboro dapat dilakukan dengan mempertimbangkan faktor-faktor lain yang mungkin memengaruhi hasil rekonstruksi. Hal ini dapat dilakukan dengan memperluas cakupan data untuk memperoleh gambaran yang lebih utuh dan lengkap, misalnya data cuaca, data wisatawan, peristiwa khusus, dll. Selain itu, dapat juga dilakukan analisis pada periode waktu lain yang lebih panjang untuk mendapatkan pemahaman yang lebih mendalam mengenai pola lalu lintas di Jalan Malioboro.
3. Perbandingan hasil estimasi dengan data *ground truth* dapat diperluas dengan menggunakan metode evaluasi yang lebih kompleks. Evaluasi juga dapat dilakukan dengan mempertimbangkan faktor-faktor lain yang mungkin memengaruhi hasil estimasi. Selain itu, penelitian selanjutnya juga dapat mempertimbangkan penggunaan data *ground truth* lain yang lebih detail dan lengkap untuk memperoleh hasil evaluasi yang lebih akurat.

DAFTAR PUSTAKA

- [1] Z. Wang, M. Lu, X. Yuan, J. Zhang, and H. V. D. Wetering, “Visual traffic jam analysis based on trajectory data,” *IEEE Transactions on Visualization and Computer Graphics*, vol. 19, pp. 2159–2168, 2013.
- [2] T. Kyaw, N. Oo, and W. Zaw, “Estimating travel speed of yangon road network using gps data and machine learning techniques,” in *International Conference on Electrical Engineering/Electronics, Computer, Telecommunications and Information Technology*, 2018, pp. 102–105.
- [3] D. J. B. Marga, *Pedoman Kapasitas Jalan Perkotaan*. Kementerian Pekerjaan Umum dan Perumahan Rakyat, 2023.
- [4] D. J. B. M. DIREKTORAT PEMBINAAN JALAN KOTA, “Panduan survai dan perhitungan waktu perjalanan lalu lintas (no. 001/t/bnkt/1990),” 1990.
- [5] M. Forghani, F. Karimipour, and C. Claramunt, “From cellular positioning data to trajectories: Steps towards a more accurate mobility exploration,” *Transportation Research Part C: Emerging Technologies*, vol. 117, p. 102666, 08 2020.
- [6] D. Satrinia and G. Saptawati, “Traffic speed prediction from gps data of taxi trip using support vector regression,” in *International Conference on Data and Software Engineering*, 2017, pp. 1–6.
- [7] A. Aasa, P. Kamenjuk, E. Saluveer, J. Šimbera, and J. Raun, “Spatial interpolation of mobile positioning data for population statistics,” *Journal of Location Based Services*, vol. 15, pp. 239 – 260, 2021.
- [8] R. Ahas, A. Aasa, A. Roose, Mark, and S. Silm, “Evaluating passive mobile positioning data for tourism surveys: An estonian case study,” *Tourism Management*, vol. 29, pp. 469–486, 2008.
- [9] A. Rakhman, L. E. Nugroho, W. Widyawan, and N. K. Utami, “From gps to maps: Path reconstruction techniques for understanding people mobility with low-sampling-rate data,” in *2023 3rd International Conference on Intelligent Cybernetics Technology and Applications (ICICyTA)*, 2023, pp. 142–147.
- [10] X. Zhou, W. Wang, and L. Yu, “Traffic flow analysis and prediction based on gps data of floating cars,” 2013, pp. 497–508.
- [11] E. Tramontana and G. Verga, “Demo: Get spatio-temporal flows from gps data,” *2018 IEEE International Conference on Smart Computing (SMARTCOMP)*, pp. 282–284, 2018.
- [12] S. Wang, J. Zhao, C. Shao, C. Dong, and C. Yin, “Truck traffic flow prediction based on lstm and gru methods with sampled gps data,” *IEEE Access*, vol. 8, pp. 208 158–208 169, 2020.
- [13] P. Kementerian Pekerjaan Umum dan Perumahan Rakyat, Badan Pengembangan Sumber Daya Manusia, *Pelatihan Kapasitas Jalan Luar Kota Modul 1 Konsep Dasar Lalu Lintas dan Kapasitas Jalan Luar Kota*. Kementerian Pekerjaan Umum dan Perumahan Rakyat, 2019.

- [14] N. Haque, S. Halder, M. Islam, R. Nag, M. R. Alam, and M. Hassan, "Traffic speed study," 09 2013.
- [15] P. Kementerian Pekerjaan Umum dan Perumahan Rakyat, Badan Pengembangan Sumber Daya Manusia, *Pelatihan Kapasitas Jalan Luar Kota Modul 8 Perencanaan Survei Jalan Luar Kota dan Persiapan Seminar*. Kementerian Pekerjaan Umum dan Perumahan Rakyat, 2019.
- [16] N. Rowan and C. J. Keese, "A study of factors influencing traffic speeds," *Highway Research Board bulletin*, vol. 341, pp. 30–76, 1962.
- [17] Z. Liang and Y. Xiao, "Analysis of factors influencing expressway speeding behavior in china," *PLoS ONE*, vol. 15, 2020.
- [18] N. Garber and R. Gadiraju, "Factors affecting speed variance and its influence on accidents," *Transportation Research Record*, 1989.
- [19] B. K. D. J. B. Marga, *Manual Kapasitas Jalan Indonesia (MKJI) 1997*. Jakarta: Bina Karya, 1997.
- [20] S. Khayati, Widyawan, and A. R. Pratama, "Pengembangan academic sandbox untuk eksplorasi mobilitas manusia berdasar data lokasi telepon seluler selama pandemi covid-19," Universitas Gadjah Mada, 2022.
- [21] I. Noviyanti, P. D. Prabawa, D. P. Sari, A. Koswara, T. Lestari, M. H. Fahyuananto, and E. Setiawan, "Towards big data as official statistics: Case study of the use of mobile positioning data to delineate metropolitan areas in indonesia," *Statistical journal of the IAOS*, vol. 36, pp. 943–954, 2020.
- [22] P. Chao, Y. Xu, W. Hua, and X. Zhou, "A survey on map-matching algorithms," *ArXiv*, vol. abs/1910.13065, 2019.
- [23] C. E. White, D. Bernstein, and A. Kornhauser, "Some map matching algorithms for personal navigation assistants," *Transportation Research Part C-emerging Technologies*, vol. 8, pp. 91–108, 2000.
- [24] A. Erianda and F. Nova, "Penerapan map-matching method pada aplikasi mobile peraturan zonasi berdasarkan rencana detail tata ruang (rdtr)," *JITSI : Jurnal Ilmiah Teknologi Sistem Informasi*, 2023.
- [25] M. Quddus, W. Ochieng, and R. Noland, "Current map-matching algorithms for transport applications: State-of-the art and future research directions," *Transportation Research Part C-emerging Technologies*, vol. 15, pp. 312–328, 2007.
- [26] L. Xi, Q. Liu, M. Li, and Z. Liu, "Map matching algorithm and its application," 2007, pp. 740–746.
- [27] M. Skrodzki, "The k-d tree data structure and a proof for neighborhood computation in expected logarithmic time," *ArXiv*, vol. abs/1903.04936, 2019.
- [28] J. Jo, J. Seo, and J.-D. Fekete, "A progressive k-d tree for approximate k-nearest neighbors," *2017 IEEE Workshop on Data Systems for Interactive Analysis (DSIA)*, pp. 1–5, 2017.

- [29] L. Qu, Y. Zhou, J. Li, Q. Yu, and X. Jiang, "Hmm-based map matching and spatio-temporal analysis for matching errors with taxi trajectories," *ISPRS Int. J. Geo Inf.*, vol. 12, p. 330, 2023.
- [30] P. Newson and J. Krumm, "Hidden markov map matching through noise and sparseness," *Proceedings of the 17th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems*, 2009.
- [31] M. Tortora, E. Cordelli, and P. Soda, "Pytrack: A map-matching-based python toolbox for vehicle trajectory reconstruction," *IEEE Access*, vol. 10, pp. 112 713–112 720, 2022.
- [32] A. Graser, "Movingpandas: Efficient structures for movement data in python," *GI Forum*, 2019.
- [33] W. Kirch, "Pearson's correlation coefficient," pp. 1090–1091, 2008. [Online]. Available: https://doi.org/10.1007/978-1-4020-5614-7_2569
- [34] P. Schober, C. Boer, and L. Schwarte, "Correlation coefficients: Appropriate use and interpretation," *Anesthesia and Analgesia*, vol. 126, p. 1763–1768, 2018.
- [35] E. J. Keogh and M. Pazzani, "Derivative dynamic time warping," pp. 1–11, 2001.
- [36] M. Muller, "Dynamic time warping," *Information Retrieval for Music and Motion*, vol. 2, pp. 69–84, 01 2007.
- [37] E. J. Keogh and C. Ratanamahatana, "Exact indexing of dynamic time warping," *Knowledge and Information Systems*, vol. 7, pp. 358–386, 2002.
- [38] R. A. Azdy and F. Darnis, "Use of haversine formula in finding distance between temporary shelter and waste end processing sites," in *Journal of Physics: Conference Series*, vol. 1500, 2020.
- [39] J. Yuan, Y. Zheng, C. Zhang, W. Xie, X. Xie, G. Sun, and Y. Huang, "T-drive: driving directions based on taxi trajectories," pp. 99–108, 2010.
- [40] Q. Li, Y. Zheng, X. Xie, Y. Chen, W. Liu, and W.-Y. Ma, "Mining user similarity based on location history," p. 34, 2008.
- [41] P. Zandbergen and S. J. Barbeau, "Positional accuracy of assisted gps data from high-sensitivity gps-enabled mobile phones," *Journal of Navigation*, vol. 64, pp. 381 – 399, 2011.
- [42] Y. Zheng, "Trajectory data mining," *ACM Transactions on Intelligent Systems and Technology (TIST)*, vol. 6, pp. 1 – 41, 2015.
- [43] K. Zheng, Y. Zheng, X. Xie, and X. Zhou, "Reducing uncertainty of low-sampling-rate trajectories," *2012 IEEE 28th International Conference on Data Engineering*, pp. 1144–1155, 2012.
- [44] A.-S. Al-Sobky and R. M. Mousa, "Estimating free flow speed using google maps api: accuracy, limitations, and applications," *Advances in Transportation Studies*, vol. Section A, p. 49, 03 2020.

- [45] L. A. Paramesti and D. Atunggal, "Suitability level analysis of google maps travel time and traffic density classification," vol. 2, 2019.
- [46] A. Macarulla Rodriguez, C. Tiberius, R. van Bree, and Z. Geradts, "Google timeline accuracy assessment and error prediction," *Forensic Sciences Research*, vol. 3, no. 3, pp. 240–255, 10 2018.